

Dotreniravanje LLM-ova s podacima iz medicinskih smjernica	1.0
Tehnička dokumentacija	Datum: 26/1/2026

Dotreniravanje LLM-ova s podacima iz medicinskih smjernica Tehnička dokumentacija Verzija <1.0>

Studentski tim: Lara Ćorić
Ana Gašperov
Jana Gazdek
Mia Krstičević

Nastavnik: Izv. prof. dr. sc. Alan Jović

Dotreniravanje LLM-ova s podacima iz medicinskih smjernica	1.0
Tehnička dokumentacija	Datum: 26/1/2026

Sadržaj

1.	Opis razvijenog
proizvoda	32.
	Tehničke
značajke	53.
	Upute za
korištenje	74.
	Literatura
	9

Dotreniravanje LLM-ova s podacima iz medicinskih smjernica	1.0
Tehnička dokumentacija	Datum: 26/1/2026

Tehnička dokumentacija

1. Opis razvijenog proizvoda

Prikupljanje i predobrada podataka

U početnoj fazi projekta korišteno je pet kliničkih smjernica Europskog kardiološkog društva (ESC Guidelines), preuzetih sa službene mrežne stranice

[1]<https://www.escardio.org/Guidelines/Clinical-Practice-Guidelines>. Analizirani dokumenti obuhvaćali su smjernice *Valvular Heart Disease* (2025), *Dyslipidaemias* (2025), *Elevated Blood Pressure and Hypertension* (2024), *Atrial Fibrillation* (2024) te *Ventricular Arrhythmias and the Prevention of Sudden Cardiac Death* (2022). Iz navedenih izvora prikupljeno je ukupno 250 smjernica.

Svaka smjernica oblikovana je kao par pitanje–odgovor, pri čemu su pitanja i odgovori osmišljeni i izvedeni iz sadržaja izvornih članaka. Budući da su dokumenti bili dostupni u PDF formatu, bilo ih je potrebno parsirati i transformirati u strukturirani *.json* format prikladan za postupak fine-tunanja jezičnog modela. Parsiranje članaka provedeno je uz pomoć LLaMA AI parsera. Prompt korišten za parsiranje bio je dizajniran tako da osigura uključivanje svih tablica, opisivanje svih slika i grafova te pravilnu i konzistentnu ekstrakciju teksta.

Dobiveni podaci organizirani su u JSON strukturu s značajkama *page* i *text*, gdje je svaki zapis sadržavao broj stranice i pripadajući tekstualni sadržaj. Uočene nepravilnosti u JSON zapisima, poput viška uglatih zagrada ili strukturnih nekonzistentnosti, dodatno su ispravljene korištenjem prilagođenih Python skripti.

Tijekom faze obrade podataka identificirana je značajna količina šuma u parsiranom tekstu, koji je bilo nužno ukloniti prije fine-tunanja modela. U tu svrhu implementirana je funkcija *clean_text()*, kojom se tekst obrađivao u batch-evima. Tom funkcijom uklanjanje su oznake za novi red, dijelovi vezani uz reference i citiranja, standardne oznake unutar članaka poput „ESC Guidelines“, višestruki tabulatori, numeričke oznake poglavlja i potpoglavlja, URL-ovi te suvišna interpunkcija i artefakti generirani parserom.

Dodatno, pomoću funkcije *remove_repeat()* uklonjene su ponavljajuće rečenice unutar pojedinih stranica, ukoliko su bile prisutne. Nakon završetka faze čišćenja i obrade podataka pristupilo se glavnoj fazi projekta, odnosno fine-tunanju modela. Prije samog treniranja provedena je tokenizacija korištenjem klase *AutoTokenizer*, pri čemu je maksimalna duljina ulaznog niza (*max_length*) postavljena na 2048 tokena.

Dotreniravanje LLM-ova s podacima iz medicinskih smjernica	1.0
Tehnička dokumentacija	Datum: 26/1/2026

Fine tuning

Kao baza korišten je Mistral (Mistral-7B-v0.3) model. Prvi ključni korak bila je priprema tokenizera.

Umjesto treniranja svih sedam milijardi parametara, što je skupo i sporo, korištena je QLoRA (Quantized Low-Rank Adaptation) tehnika. Prvo je primijenjena 4-bitna kvantizacija pomoću *bitsandbytes* biblioteke, čime je drastično smanjena potrošnja VRAM-a bez gubitka bitnih informacija. Uz pomoć LoRA-e nadalje se zamrzavaju težine osnovnog modela i dodaju mali, trenirani adapteri. Ovim pristupom trenira se samo mali postotak dodatnih parametara koji uče specifični rječnik i domensko znanje članaka.

S modelom koji je sada spreman za učenje, model se šalje u SFT Trainer, uz unaprijed definirane parametre treniranja. Odabrana konfiguracija pokazala se najboljom jer je postigla dobar rezultat bez prevelikih pogrešaka, ali i bez preniskog gubitka koji bi upućivao na opasnost od prenaučivosti (*overfittinga*).

U ovom koraku provedeno je sustavno podešavanje hiperparametara uz korištenje validacijskog skupa. Podaci su podijeljeni na train i validation, a više konfiguracija ispitano je s ciljem postizanja stabilno niskog gubitka (*loss*) na trenirajućem i validacijskom skupu. Optimalni parametri odabrani su prema ravnoteži između ta dva rezultata, kako bi se izbjegli i prenaučivost (*overfitting*) i podnaučivost (*underfitting*).

Nakon uspješnog domain fine-tuninga proveden je instruction fine-tuning. Budući da je osnovni (base) model primarno generator koji nastavlja niz tokena, bilo ga je potrebno dodatno naučiti da se ponaša kao asistent, odnosno da odgovara na pitanja u očekivanom formatu. Zato je pripremljen dodatni skup podataka od 300 instrukcijskih primjera u obliku instruction–input–output. Cilj ovog koraka bio je da model pouzdano prepozna upit, koristi naučeni kontekst i generira smislen, koristan odgovor u skladu sa stilom koji korisnik očekuje. Rezultat je instruction model koji je domenski prilagođen smjernicama i sposoban davati relevantne odgovore temeljene na tom znanju.

LLM as judge

Ova Jupyter bilježnica predstavlja sustav za automatizirano testiranje i evaluaciju modela umjetne inteligencije u medicinskoj domeni koristeći pristup poznat kao LLM as a Judge. Glavna poanta ove datoteke je iskoristiti napredni jezični model (u našem slučaju Google Gemini) kao stručni sudac koji procjenjuje točnost i kvalitetu odgovora koje generira drugi, specifično trenirani AI model.

Skripta na početku učitava bazu testnih pitanja iz Excel datoteke zajedno s unaprijed definiranim referentnim odgovorima koje smo pripremili i zapisali u tablici. Nakon pripreme podataka, kod prolazi kroz svako pitanje, generira odgovor pomoću ciljnog modela, a zatim šalje par odgovor i referentni odgovor modelu sucu uz detaljne upute za ocjenjivanje.

Dotreniravanje LLM-ova s podacima iz medicinskih smjernica	1.0
Tehnička dokumentacija	Datum: 26/1/2026

Model sudac analizira odgovor prema strogim kriterijima kao što su točnost, potpunost, preciznost brojčanih podataka, prisutnost halucinacija i potencijalni klinički rizik za pacijenta. Rezultat analize je strukturirani JSON zapis koji sadrži ocjene i kratka obrazloženja za svaku kategoriju, a sve se na kraju sprema u izvještaj za kasniju analizu.

2. Tehničke značajke

1. Arhitektura modela

Glavni modeli korišteni u ovom projektu su **Mistral-7B-v0.3** i **Mistral-7B-Instruct-v0.3**, jezični model temeljen na Transformer (decoder-only) arhitekturi s približno 7 milijardi parametara. Za usporedbu performansi testiran je i **Qwen-7B** model.

1.1 Metoda optimizacije i prilagodbe

- **Optimizacija:** QLoRA (4-bitna kvantizacija s NF4 tipom podataka)
- **Adapteri:** LoRA
 - Rank: 8
 - Scaling factor (α): 32
 - Ciljani moduli: q_proj , k_proj , v_proj , o_proj , $gate_proj$, up_proj , $down_proj$
- **Kontekstni prozor:** 2048 tokena

2. Trening i fino podešavanje

2.1 Domain-adaptive fine-tuning (DAFT)

- **Cilj:** domenska prilagodba modela treniranjem na medicinskim smjernicama
- **Optimizacijski algoritam:** Paged AdamW 8-bit
- **Stopa učenja:** 2×10^{-4} , s Cosine schedulerom za postupno smanjenje brzine učenja
- **Batch size:** Efektivni batch size od 8 (2 po GPU-u s 4 koraka akumulacije gradijenata)
- **Preciznost:** bfloat16
- **Tehnike učinkovitosti:** Gradient Checkpointing i Packing (spajanje više uzoraka u jedan blok radi optimizacije memorijske potrošnje i vremena treniranja)

2.2 Instruction Fine-Tuning (IF)

- **Cilj:** naučiti model da se ponaša kao asistent, tj. da prepozna je instrukciju/upit i generira strukturiran, koristan odgovor u očekivanom formatu
- **Skup podataka:** instrukcijski primjeri u formatu instruction–input–output
- **Metoda prilagodbe:** LoRA adapter (nastavak na domenski prilagođenom modelu)
- **Biblioteke i alati:** transformers, trl, peft, datasets, unsloth
- **Treniranje:** nadzirano treniranje na instrukcijskim parovima (supervised instruction tuning) s ciljem stabilnog učenja bez prenaučenosti
- **Izlaz:** instruction model koji je domenski prilagođen i sposoban odgovarati na pitanja

Dotreniravanje LLM-ova s podacima iz medicinskih smjernica	1.0
Tehnička dokumentacija	Datum: 26/1/2026

3. Podatkovni skupovi

- **Domain adaptation dataset:** Strukturirani tekstovi iz medicinskih i stručnih članaka, segmentirani u logičke cjeline (chunkove) radi bolje obrade konteksta.
- **Instruction dataset:** 300 parova u formatu Instruction–Input–Output, ručno prilagođenih za ciljani domen (biomedicina i zdravstvo), osiguravajući generiranje preciznih i stručnih odgovora.
- **Tokenizacija:**
 - Maksimalna duljina ulaza: 2048 tokena
Broj *chunkova*: 308
 - Duljina tokena: min=137, medijan=1086, p80=1539, max=2008
 - Nema ulaznih primjera dužih od 2048 tokena

4. Hardversko i softversko okruženje

- **GPU:** NVIDIA A100 i T4
- **Platforma:** Hugging Face (Transformers, PEFT, Accelerate)
- **Razvojno okruženje:** Jupyter/Google Colab
- **Softver:**
 - Python 3.12.12
 - PyTorch 2.9.0+cu126
 - CUDA 12.6
 - Transformers 4.57.6
 - Accelerate 1.12.0
 - bitsandbytes 0.49.1
 - PEFT (LoRA adapteri)

Dotreniravanje LLM-ova s podacima iz medicinskih smjernica	1.0
Tehnička dokumentacija	Datum: 26/1/2026

5. Rezultati i zaključak

5.1 Rezultati

Model	domain + instruct	instruct base + domain	base instruct
correctness_avg	0.6856	0.6504	0.57
completness_avg	0.5764	0.5736	0.5288
numerical_precision_avg	0.8440	0.79	0.678
hallucinations_avg	0.238	0.2932	0.3424
clinical_risk_avg	0.234	0.268	0.292
Overall Score	0.6310	0.612	0.5494

5.2 Zaključak

Rezultati pokazuju da fine-tuning ima pozitivan učinak, iako poboljšanja nisu ogromna. Najviše se vidi da nakon domenskog i instruction fine-tuninga model daje nešto konzistentnije i sigurnije odgovore (rjeđe halucinira i rjeđe ulazi u klinički rizične tvrdnje) Istovremeno, važno je naglasiti da je i osnovni instruct model već relativno snažan i može se solidno snaći u dijelu pitanja i bez dodatnog treniranja. Zbog toga je očekivano da dodatni fine-tuning donosi finije poboljšanje ponašanja, više u smjeru stabilnosti, usklađenosti s medicinskim stilom i manjeg rizika od izmišljanja informacija.

U konačnici, fine-tuning se isplati kao završni korak za dodatnu pouzdanost i kontrolu outputa, posebno kad je cilj medicinski kontekst.

3. Upute za korištenje

Ovaj odjeljak opisuje kako koristiti trenirani model **Mistral LoRA medicinskog chatbota** za generiranje odgovora na medicinska pitanja.

1. Hardverski zahtjevi:

- GPU s najmanje 16 GB VRAM-a (preporučeno: NVIDIA A100, L4, RTX 3090/4090).
- Minimalno 32 GB RAM-a za veće ulazne batch-eve.

Dotreniravanje LLM-ova s podacima iz medicinskih smjernica	1.0
Tehnička dokumentacija	Datum: 26/1/2026

2. Softverski zahtjevi:

- Python 3.12 ili noviji.
- PyTorch 2.9+ s podrškom za CUDA.
- Git za preuzimanje repozitorija.
- Google Colab ili lokalno okruženje s GPU podrškom (ovisno o dostupnosti hardvera)
- Hugging Face račun i pristupni token (za prijavu i preuzimanje modela, ako je potrebno)

3. Preuzimanje koda:

- *git clone https://github.com/lara-coric/medical-guidelines-llm*
- *cd medical-guidelines-llm*

4. Pokretanje modela:

- *Otvori Colab i učitaj željenu .ipybn skriptu.*
- *Slijedi upute u ćelijama (instalacija biblioteka, mount Google Drive, prijava na Hugging Face Hub).*
- *Pokreni sve bilježnice redom:*
 - *fine_tune_mistralai.ipynb* – treniranje domenskog LoRA adaptera na medicinskim smjernicama
 - *instruction_fine_tuning.ipynb* – za instrukcijsko fino podešavanje i integraciju adaptera u chat model
 - *llm_as_judge.ipynb* - evaluacija kvalitete odgovora (usporedba generiranih i referentnih odgovora pomoću Gemini modela kao suca)

Dotreniravanje LLM-ova s podacima iz medicinskih smjernica	1.0
Tehnička dokumentacija	Datum: 26/1/2026

4. Literatura

- [1] European Society of Cardiology. *Clinical Practice Guidelines*. European Society of Cardiology, <https://www.escardio.org/Guidelines/Clinical-Practice-Guidelines>, pristupljeno siječanj 2026.
- [2] Google AI. *AI Studio*. Google, <https://ai.google.dev/aistudio>, pristupljeno siječanj 2026.
- [3] LLaMA Index. *LLaMA Parse*. LLaMA Index, <https://www.llamaindex.ai/llamaparse>, pristupljeno siječanj 2026.
- [4] Maheshkar, S. *What is QLoRA*. Weights & Biases, <https://wandb.ai/sauravmaheshkar/QLoRA/reports/What-is-QLoRA---Vmlldzo2MTI2OTc5>, pristupljeno siječanj 2026.
- [5] Avanzi, A. (2023). *Effective Q&A LLM Fine-Tuning with PDF Documentation*. Medium, <https://medium.com/@ales.avanzi/effective-q-a-llm-fine-tuning-with-pdf-documentation-91b7fc458ced>, pristupljeno siječanj 2026.
- [6] SiliconFlow. *Best Open-Source LLM for Medical Industry*. SiliconFlow, <https://www.siliconflow.com/articles/en/best-open-source-LLM-for-medical-industry>, pristupljeno siječanj 2026.
- [7] YouTube. (2023). *QLoRA Tutorial*. <https://youtu.be/OtdnFtHOu40?si=qh-VI0CzT0jrTh36>, pristupljeno siječanj 2026.