

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

DIPLOMSKI RAD br. 1267

**PREPOZNAVANJE LJUDSKIH AKTIVNOSTI I
MIKRO-POKRETA POMOĆU PODATAKA S PAMETNOG
SATA ZASNOVANO NA AKTIVNOM I DUBOKOM UČENJU**

Mia Krstičević

Zagreb, lipanj 2026.

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

DIPLOMSKI RAD br. 1267

**PREPOZNAVANJE LJUDSKIH AKTIVNOSTI I
MIKRO-POKRETA POMOĆU PODATAKA S PAMETNOG
SATA ZASNOVANO NA AKTIVNOM I DUBOKOM UČENJU**

Mia Krstičević

Zagreb, lipanj 2026.

DIPLOMSKI ZADATAK br. 1267

Pristupnica: **Mia Krstičević (0036540586)**

Studij: Računarstvo

Profil: Znanost o podacima

Mentor: prof. dr. sc. Alan Jović

Zadatak: **Prepoznavanje ljudskih aktivnosti i mikro-pokreta pomoću podataka s pametnog sata zasnovano na aktivnom i dubokom učenju**

Opis zadatka:

Prepoznavanje ljudskih aktivnosti (engl. Human Activity Recognition, HAR) predstavlja jedno od važnih područja primjene nosivih uređaja u zdravstvu, sportu i rehabilitaciji. Pametni satovi opremljeni akcelometrom i žiroskopom omogućuju kontinuirano prikupljanje podataka o pokretima korisnika, no interpretacija takvih vremenskih nizova i dalje predstavlja metodološki izazov. U ovom diplomskom radu potrebno je istražiti problem prepoznavanja ljudskih aktivnosti klasifikacijskim metodama strojnog učenja te izgraditi upotrebljive modele strojnog učenja za automatizaciju prepoznavanja. Kao izvor podataka, potrebno je koristiti neki informacijsko bogat skup podataka (npr. "WISDM Smartphone and Smartwatch Activity and Biometrics Dataset"), koji treba sadržavati podatke najmanje od akcelometra i žiroskopa prikupljene s pametnog sata i/ili pametnog telefona. Potrebno je razmotriti aktivno učenje s uobičajnim algoritmima strojnog učenja (npr. XGBoost, slučajna šuma, stablo odluke). Kod aktivnog učenja model započinje s ograničenim inicijalno označenim skupom podataka te iterativno odabire najinformativnije uzorke iz testnog skupa podataka na temelju mjere nesigurnosti klasifikacije. Također, potrebno je primijeniti metode dubokog učenja za rad s vremenskim nizovima (npr. 1D konvolucijske neuronske mreže, rekurentne neuronske mreže) te ih usporediti po pitanju klasifikacijskih metrika s uobičajenim algoritmima strojnog učenja. Također, potrebno je proširiti modele strojnog učenja na prepoznavanje finijih motoričkih obrazaca, odnosno mikro-pokreta povezanih s nervoznim i repetitivnim ponašanjima poput grizenja noktiju, tresenja nogom ili pucketanja prstima. U tu svrhu potrebno je prikupiti dodatni eksperimentalni skup podataka pomoću pametnog sata uz definiranu metodologiju označavanja. Ovim proširenjem nastoji se postići primjena u praćenju stresa, anksioznosti i drugih stanja relevantnih za digitalno zdravstvo.

Rok za predaju rada: 26. lipnja 2026.

Zahvaljujem mentoru prof. dr. sc. Alanu Joviću na pomoći pri izradi diplomskog rada i stručnim savjetima.

Hvala mojoj obitelji na požrtvornosti, neizmjernoj podršci i ljubavi.

Hvala mojim prijateljicama koje su sve ove godine začinile s puno smijeha i pozitivne.

Posebne zahvale za ove gori što gledaju.

Sažetak

Prepoznavanje ljudskih aktivnosti i mikro-pokreta pomoću podataka s pametnog sata zasnovano na aktivnom i dubokom učenju

Mia Krstičević

U radu je istraženo prepoznavanje ljudskih aktivnosti i mikro-pokreta. Za istraživanje je korišten skup podataka WISDM, proširen s tri aktivnosti: grickanje noktiju, treskanje nogom i listanje kratkih videozapisa. Podaci za proširene aktivnosti prikupljeni su pomoću mobilne aplikacije SensorLogger. Obrada podataka uključivala je filtraciju, segmentaciju i ekstrakciju značajki, nakon čega su primijenjene metode tradicionalnog, aktivnog i dubokog učenja.

Najviša točnost od 0,771 postignuta je modelom LightGBM na skupu podataka koji objedinjuje podatke pametnog sata i mobilnog telefona. Tradicionalni modeli postigli su bolje rezultate od modela dubokog učenja uz kraće vrijeme učenja. Na proširenom skupu podataka s tri dodatne aktivnosti LightGBM je postigao točnost od 0,736. Aktivno učenje nije nadmašilo nadzirano učenje, ali je uz manju količinu označenih podataka omogućilo postizanje rezultata bliskih onima ostvarenima nadziranom učenjem.

Ključne riječi: raspoznavanje ljudskih aktivnosti, mikro-pokreti, pametni sat, WISDM, strojno učenje, duboko učenje, aktivno učenje

Abstract

Human activity and micro-movement recognition using smartwatch sensor data based on active and deep learning

Mia Krstičević

This study investigates the recognition of human activities and micro-movements. The WISDM dataset was used for the study and extended with three additional activities: nail biting, leg tremor, and scrolling. Data for the additional activities were collected using the SensorLogger mobile application. Data processing included filtering, segmentation, and feature extraction, followed by the application of traditional, active, and deep learning methods.

The highest accuracy of 0,771 was achieved by the LightGBM model on the dataset combining smartwatch and smartphone data. Traditional models outperformed deep learning models while requiring shorter training times. On the extended dataset with three additional activities, LightGBM achieved an accuracy of 0,736. Active learning did not outperform supervised learning but achieved comparable results while requiring fewer labeled data.

Keywords: human activity recognition, micro-movements, smartwatch, WISDM, machine learning, deep learning, active learning

Sadržaj

Sažetak	1
Abstract	2
1. Uvod	5
2. Prepoznavanje ljudskih aktivnosti	6
2.1. Definicija i primjene sustava HAR	6
2.2. pristupi prepoznavanju aktivnosti	7
2.3. Arhitektura sustava HAR	7
2.4. Izazovi u sustavu HAR	8
3. Nosivi uređaji i senzori	9
3.1. Definicija i karakteristike nosivih uređaja	9
3.2. Pametni sat	9
3.3. Oblikovanje nosivih uređaja i ograničenja	10
4. Skup podataka	12
4.1. Skup podataka WISDM	12
4.2. Prikupljanje i proširivanje skupa podataka	12
5. Inercijski senzori za praćenje kretanja	17
5.1. Inercijski senzori	17
5.2. Komponente pametnog sata	17
5.2.1. Akcelerometar	17
5.2.2. Žiroskop	18

6. Vremenski nizovi u podacima senzora	19
6.1. Definicija i karakteristike vremenskih nizova	19
6.2. Šum i filtriranje	21
7. Obrada i analiza podataka u sustavima HAR	24
7.1. Predobrada podataka	24
7.2. Deskriptivna analiza	24
7.3. Segmentacija	25
7.4. Ekstrakcija značajki	25
7.5. Podjela podataka i transformacija	27
8. Klasifikacijski modeli i učenje	29
9. Aktivno učenje	31
10. Rezultati	32
10.1. Opseg evaluacije i glavni skup podataka	34
10.2. Usporedba skupova podataka	34
10.3. Rezultati na glavnom skupu podataka	35
10.3.1. Analiza po klasama aktivnosti	36
10.4. Rezultati aktivnog učenja	37
10.5. Utjecaj PCA redukcije	38
11. Diskusija	39
12. Zaključak	41
Literatura	42
Izjava o korištenju umjetne inteligencije	46

1. Uvod

Prepoznavanje ljudskih aktivnosti (engl. *Human Activity Recognition*, HAR) područje je umjetne inteligencije koje razvija metode za automatsko raspoznavanje i klasifikaciju ljudskog pokreta. Zahvaljujući širokoj primjeni na nosivim uređajima, sustavi HAR postali su sastavni dio rješenja u područjima zdravstvene skrbi, rehabilitacije, nadzornih sustava te robotike. Iako dosadašnja tehnologija uspješno prepoznaje makro-pokrete poput hodanja ili trčanja, prepoznavanje finijih motoričkih radnji, tzv. mikro-pokreta ostaje izazovno područje u kojem je potrebna znatno veća preciznost senzorskih mjerenja i naprednija obrada podataka.

Cilj ovog rada jest razviti i evaluirati klasifikacijske modele sposobne za precizno prepoznavanje makro i mikro-pokreta. U tu svrhu korišten je skup podataka WISDM [1], koji je nadopunjen s tri mikro-pokreta: grickanje noktiju (*nail_biting*), treskanje nogom (*leg_tremor*) i listanje kratkih videozapisa na društvenim mrežama (engl. *scrolling*). Priкупljanje dodatnih podataka postignuto je aplikacijom Sensor Logger na pametnom telefonu.

Provedeno istraživanje obuhvaća cjelovit postupak obrade signala: od deskriptivne analize, filtracije i segmentacije u vremenske prozore, do ekstrakcije značajki te učenja i evaluacije modela. U radu je provedena komparativna analiza tradicionalnih algoritama strojnog učenja te modela dubokog učenja. Dodatna pozornost posvećena je primjeni aktivnog učenja kao metode za optimizaciju procesa označavanja podataka i potencijalno poboljšanje izvedbe modela.

2. Prepoznavanje ljudskih aktivnosti

2.1. Definicija i primjene sustava HAR

Prepoznavanje ljudskih aktivnosti postiže se prikupljanjem i obradom podataka te razvojem modela strojnog učenja koji raspoznaje različite pokrete čovjeka [2]. Temeljni cilj sustava HAR jest razvoj tehnologije koja što preciznije interpretira i razumije ljudsko ponašanje u stvarnom vremenu [2].

Sustavi HAR primarno su usmjereni na analizu aktivnosti svakodnevnog života, a u literaturi ih se klasificira na statičke, poput stajanja i sjedenja, te dinamičke, kao što su hodanje ili trčanje. Nadalje, aktivnosti se mogu klasificirati na jednostavne i složene. Složenim aktivnostima smatraju se one koje se sastoje od kombinacije jednostavnih pokreta. Primjerice, igranje odbojke predstavlja složenu aktivnost sastavljenu od niza elementarnih radnji, kao što su prihvati lopte, njezino izbacivanje u zrak te izvođenje servisa. U kontekstu analize mikro-pokreta, kao relevantan primjer može poslužiti uporaba pribora za jelo, gdje se aktivnost može rastaviti na zahvat pribora, rezanje hrane te koordinirani pokret ruke prema ustima [2].

Sustavi HAR primjenjuju se u nizu različitih područja. U zdravstvu se primjenjuju za kontinuirano praćenje kroničnih bolesnika, detekciju padova te kao potpora u procesu rehabilitacije. U sportu se mogu koristiti za analizu izvođenja pokreta sportaša te praćenje parametara i opterećenja mišića. Također, koristi se i u sustavima nadzornih kamera za detekciju neobičnog ponašanja u javnim prostorima, kao i u području robotike, virtualne stvarnosti (VR) te proširene stvarnosti (AR) [2].

2.2. pristupi prepoznavanju aktivnosti


Razlikuju se dva temeljna pristupa prikupljanju podataka za sustav HAR: pristup temeljen na senzorima (engl. *sensor-based*) te pristup temeljen na vizualnim podacima (engl. *vision-based*) [3].

U okviru vizualnog pristupa podaci se prikupljaju iz videozapisa i slika snimljenih pametnim telefonima, uređajima Kinect, nadzornim kamerama (engl. *Closed-Circuit Television*, CCTV), videokamerama i ostalim sličnim uređajima [3]. Kamerama se bilježe pokreti osobe, zbog čega se ovaj pristup svrstava u domenu računalnog vida i prepoznavanja uzoraka [2]. Glavna prednost vizualnog pristupa jest njegova neinvazivnost i što se od ispitanika ne zahtijeva nošenje dodatne opreme.

Senzorski pristup temelji se na podacima koji su prikupljeni s mobilnim senzorima (gdje su senzori ugrađeni u pametne telefone) te nosivim senzorima. Moguće je i istodobno korištenje obje vrste senzora [3]. Iako senzorski pristup u pravilu pruža veću preciznost mjerenja, njegov nedostatak je u tome što korisnici trebaju nositi odgovarajuće uređaje. Točnost sustava HAR općenito ovisi o nizu čimbenika, uključujući okolišne uvjete i kut snimanja te složenost samog pokreta [3]. Unatoč prednostima senzorskog pristupa, veći dio postojeće literature oslanja se na vizualne podatke [3]. U okviru ovog rada fokus je stavljen na sustave HAR koji se temelje na podacima prikupljenima senzorima.

2.3. Arhitektura sustava HAR

Arhitektura sustava HAR može se rastaviti na pet glavnih faza [4]. U prvoj fazi odabire se odgovarajući senzor, ovisno o prirodi aktivnosti koja se snima (najčešće se radi o akcelerometru ili žiroskopu). Druga faza je prikupljanje podataka, pri čemu se iz senzora bilježe vremenski nizovi. Treća faza je ekstrakcija i selekcija značajki, u kojoj se iz sirovih podataka izdvajaju one značajke koje najbolje opisuju promatrane aktivnosti. Četvrta faza je učenje modela strojnog učenja, kada se prepoznaju i klasificiraju pokreti. Naposljetku, u petoj fazi provodi se testiranje modela, pri čemu se ispituje njegova izvedba na dotad neviđenim podacima [3]. Navedeni koraci (osim odabira senzora) prikazani su na slici 2.1., a isti metodološki okvir primjenjuje se i u ovom radu.



Slika 2.1. Arhitektura sustava HAR. Preuzeto iz: [5].

2.4. Izazovi u sustavu HAR

Unatoč napretku i širokoj primjeni sustava HAR, u njihovoj implementaciji i dalje postoje brojna ograničenja i izazovi. Jedan od glavnih problema jest varijabilnost u izvođenju pokreta među subjektima. Različite osobe izvode iste aktivnosti na različite načine, što otežava generalizaciju naučenih modela [2]. Pritom varijabilnost nije prisutna samo između različitih osoba. Ista osoba može izvoditi pokrete različito, ovisno o razini umora, fizičkom stanju i okolišnim uvjetima.

Također, prikupljanje podataka vremenski je i financijski zahtjevan proces. Čest problem predstavljaju netočno označavanje podataka i pogrešna mjerenja. Do pogrešnog označavanja dolazi kada je okvir jedne aktivnosti podijeljen u dva ili više različitih okvira, što za posljedicu ima gubitak korisnih informacija prilikom segmentacije [2]. Pomak senzora tijekom snimanja također može negativno utjecati na kvalitetu prikupljenih podataka [3].

Dodatni izazov predstavlja detekcija aktivnosti u stvarnom vremenu [3]. U nekim primjenama, kao što su kontinuirano praćenje stanja pacijenata u zdravstvu ili detekcija sumnjivog ponašanja putem nadzornih kamera, neophodna je obrada podataka bez kašnjenja. Stoga je potrebno oblikovati računalno i memorijski učinkovit sustav koji dovoljno brzo prima i obrađuje ulazne informacije, klasificira ciljnu aktivnost te istovremeno održava visoku točnost modela. Ovo se smatra jednim od zahtjevnijih problema u području HAR-a. Navedeni problem posebno dolazi do izražaja kod modela dubokog učenja, koji su računalno zahtjevni i stoga nepogodni za primjene u stvarnom vremenu [2]. Generalno, obrada velikih skupova podataka (engl. *large-scale datasets*) zahtijeva znatne računalne resurse, što predstavlja ograničenje u praktičnoj primjeni.

3. Nosivi uređaji i senzori

3.1. Definicija i karakteristike nosivih uređaja


Nosivi uređaji su autonomni, neinvazivni uređaji koji kroz određeni vremenski period prate određene parametre te pružaju povratnu informaciju korisniku [6]. Smješteni su na tijelu ili odjeći korisnika, a putem senzora bilježe odgovarajuće parametre, lokalno ih obrađuju i održavaju komunikaciju s poslužiteljem [6]. U okviru ovog rada fokus je stavljen na senzorske podatke prikupljene nosivim uređajem, pametnim satom.

Ovisno o namjeni, pojedini uređaji zahtijevaju obradu podataka u stvarnom vremenu, dok neki bilježe aktivnost pa se kasnije obrađuju [6]. Ovisno o vrsti ugrađenih senzora, nosivim uređajima mogu se pratiti različiti parametri. Fiziološki parametri obuhvaćaju, primjerice, broj otkucaja srca, zasićenost krvi kisikom (SpO₂), temperaturu tijela i puls [6]. Uz fiziološke, moguće je pratiti i biokemijske parametre, kao što su razina glukoze u krvi, elektroliti i pH vrijednost [7]. Akcelerometrom i žiroskopom mjere se ubrzanje i rotacijsko gibanje uređaja.

3.2. Pametni sat

Glavne komponente nosivih uređaja uključuju senzor ili skup senzora, modul za prikupljanje podataka (engl. *data collector*), nosivo računalo te udaljeni poslužitelj [7]. Nosivi uređaji često bežično komuniciraju s mobilnim uređajima. Mogu se povezati s mrežom, putem koje se podaci prenose i pohranjuju na poslužitelj, kao što je prikazano na slici 3.1.

Senzor je uređaj, modul ili podsustav koji detektira promjene u svojoj okolini te ih pretvara u električne signale pogodne za računalnu obradu [9]. U slučaju pametnog



Slika 3.1. Shematski prikaz sustava nosivih uređaja [8]

sata, koji uz akcelerometar i žiroskop sadrži i brojne druge senzore, akcelerometar mjeri linearno ubrzanje, dok žiroskop mjeri kutnu brzinu. Prikupljeni podaci mogu se obrađivati na samom uređaju, a prema potrebi se bežičnom komunikacijom mogu prenijeti na povezani uređaj ili udaljeni poslužitelj radi daljnje obrade i analize [7]. Na temelju obrađenih podataka određeni nosivi uređaji mogu generirati upozorenja (engl. *alert*). Primjerice, pri detekciji pada starije osobe, pametni sat može generirati upozorenje i poslati obavijest korisniku, skrbniku ili zdravstvenoj službi (slika 3.1.).

Povezivanje senzora s poslužiteljem može se ostvariti bežično, putem tehnologija Bluetooth, Wi-Fi, IR, GSM i GPRS, ili žičano, putem Ethernet, USB-a i sličnih sučelja [7]. Bežična komunikacija preferirana je u praksi jer omogućuje kontinuirano snimanje podataka bez ometanja korisnikovih aktivnosti.

3.3. Oblikovanje nosivih uređaja i ograničenja

Ispravno oblikovanje nosivih uređaja preduvjet je za njihovu uspješnu primjenu. Među glavnim zahtjevima ističe se ergonomičnost i udobnost. Uređaj treba biti oblikovan tako da odgovara anatomiji korisnika, da ne uzrokuje nelagodu pri dugotrajnom nošenju te da omogućuje prirodno kretanje [7]. Uz to, uređaj mora biti otporan na vanjske čimbenike kao što su temperatura, vlaga te znojenje tijela, što je osobito relevantno kod pametnih satova [7].

Važan zahtjev kod pametnih satova jest potrošnja energije, odnosno mogućnost du-

gotrajnog rada bez učestalog punjenja. Potrošnja energije treba biti što manja, osobito kada uređaj kontinuirano prikuplja podatke sa senzora. U tu se svrhu primjenjuju punjive baterije i niskoenergetske komponente [7]. Potrebno je osigurati sigurnost korisnika te autonomnost, odnosno sposobnost uređaja da funkcionira automatski bez potrebe za stalnom ljudskom intervencijom. Sve komponente uređaja i njihov dugoročni utjecaj na korisnika potrebno je odgovarajuće ispitati [7].

4. Skup podataka

4.1. Skup podataka WISDM

Kao skup podataka korišten je WISDM (*Wireless Sensor Data Mining*) Smartphone and Smartwatch Activity and Biometrics Dataset, objavljen 2019. godine [1]. Podaci su prikupljeni pomoću pametnog sata i pametnog telefona. Korišteni pametni telefoni bili su Google Nexus 5/5X ili Samsung Galaxy S5 s operacijskim sustavom Android 6.0, dok je za pametni sat korišten LG G Watch s operacijskim sustavom Android Wear 1.5. Skup podataka sadrži snimanja 51 ispitanika koji su izveli 18 različitih aktivnosti, svaku u trajanju od tri minute [1]. Svaki ispitanik nosio je pametni sat na dominantnoj ruci, a pametni telefon u džepu.

U navedenom skupu podataka korištena je frekvencija uzorkovanja od 20 Hz, što znači da su uzorci prikupljeni svakih 50 ms. Pametni sat opremljen je akcelerometrom i žiroskopom kojima se mjere brzina, smjer kretanja te kutovi pokreta. Nakon što su podaci prikupljeni senzorima, prenose se na poslužitelj putem Bluetootha. Sve snimljene aktivnosti s odgovarajućim oznakama, prikazane su u tablici 4.1., uključujući i dodatne aktivnosti označene slovima T, U i V (snimljeni mikro-pokreti). Uz svaku aktivnost navedena je pripadajuća oznaka koja služi kao ključ za identifikaciju aktivnosti u skupu podataka. Svaka datoteka akcelerometra i žiroskopa sadrži zapise vremenskih nizova senzora u sljedećem formatu: Subject-id, Activity Code, Timestamp, x, y, z.

4.2. Prikupljanje i proširivanje skupa podataka

Uz navedeni skup podataka, implementirana su tri dodatna pokreta (mikro-pokreti). Prikupljanje podataka provedeno je pomoću pametnog telefona i mobilne aplikacije SensorLogger [10]. Kako bi pametni telefon funkcionalno zamijenio pametni sat, uređaj je

čvrsto fiksiran na zapešće ispitanika uporabom marame (vidi sliku 4.1.a). Bitno je da uređaj bude stabilno pričvršćen kako bi se izbjeglo generiranje šuma u senzorskim signalima. Prednost ovog pristupa je što se aplikacija SensorLogger može instalirati na uređaje s operacijskim sustavima iOS i Android, što je omogućilo prikupljanje podataka s obiju vrsta uređaja.

Ideja je proširiti i nadopuniti postojeći skup podataka dodatnim mikro-pokretima koji se javljaju kao znak nervoze ili tjeskobe, a koji su često prisutni kod učenika i studenata. Konkretno, istraživane aktivnosti uključuju: grickanje noktiju, treskanje nogom te pregledavanje kratkih sadržaja na društvenim mrežama (s platformi TikTok i Instagram). Aktivnost treskanja nogom snimana je tako da je ruka s pričvršćenim uređajem bila oslonjena na koljeno, čime se omogućilo precizno bilježenje vibracija i pokreta noge (vidi sliku 4.1.b).

Motivacija za prepoznavanje upravo ovih aktivnosti leži u mogućnosti razvoja sustava koji bi korisniku pravovremeno poslao obavijest ili motivacijsku poruku s ciljem da se osoba opusti ili prekine neku nepoželjnu naviku. Odabir zabilježavanja grickanja noktiju i treskanja nogom su iz razloga što je to vrlo česta navika, dok aktivnost pregledavanje kratkih sadržaja je odabrana jer studenti često pribjegavaju takvom ponašanju kao obliku odgađanja obveza kada trebaju obaviti određeni zadatak.


U istraživanju je sudjelovalo 40 ispitanika, od kojih 26 ženskog i 14 muškog spola. Ostali deskriptivni podaci prikazani su u tablici 4.2. Svaka aktivnost snimana je tri puta u trajanju od jedne minute, uz pauze između pojedinačnih snimanja, po uzoru na način prikupljanja podataka u skupu WISDM. Budući da su za svakog ispitanika snimana tri mikro-pokreta, svaki je ispitanik imao ukupno devet snimanja, odnosno devet minuta zapisa. S obzirom na korišteni uređaj, distribucija ispitanika prema operacijskom sustavu pametnog telefona prikazana je u tablici 4.3. 80% ispitanika koristila je uređaj s operacijskim sustavom iOS, dok 20 % je koristilo uređaj s operacijskim sustavom Android. U skupu podataka WISDM subjekti su označeni identifikatorima od 1600 do 1650, stoga su novi subjekti koji su snimali mikro-pokrete označeni identifikatorima od 1651 nadalje.

Završni skup podataka, koji objedinjuje izvorni skup podataka WISDM i prošireni dio

s trima dodatnim aktivnostima, sadrži 3 934 938 zapisa prikupljenih akcelerometrom i žiroskopom. Analizom raspodjele klasa unutar skupa podataka utvrđeno je kako su one ravnomjerno zastupljene, pri čemu svaka klasa obuhvaća približno 4,9 % ukupnog volumena podataka. Na lijevoj strani slike 4.2. prikazan je broj uzoraka po pojedinoj klasi aktivnosti, dok desna strana slike prikazuje kružni dijagram distribucije klasa. Iz kružnog dijagrama se može dodatno potvrditi da je zastupljenost klasa uravnotežena. Uravnoteženost klasa je prvi korak prema izradi robusnog i generaliziranog modela.



(a) Uređaj pričvršćen na zapešće ispitanika




(b) Prikaz snimanja *leg_tremor*

Slika 4.1. Prikupljanje podataka

Tablica 4.1. Aktivnosti korištene u skupu podataka

Oznaka	Aktivnost	Oznaka	Aktivnost
A	Hodanje	L	Jedenje sendviča
B	Trčanje	M	Udaranje nogom loptu
C	Penjanje stepenicama	O	Hvatanje teniske loptice
D	Sjedenje	P	Vođenje košarkaške lopte
E	Stajanje	Q	Pisanje
F	Tipkanje po tipkovnici	R	Pljeskanje
G	Pranje zubi	S	Slaganje odjeće
H	Jedenje juhe	T	Listanje kratkih videozapisa
I	Jedenje čipsa	U	Grickanje noktiju
J	Jedenje tjestenine	V	Treskanje nogom
K	Pijenje iz šalice		



Slika 4.2. Raspodjela aktivnosti

Tablica 4.2. Demografske karakteristike ispitanika

Karakteristika	Vrijednost
Broj ispitanika	40
Ženski ispitanici	26
Muški ispitanici	14
Prosječna dob	24,82
Medijan dobi	23,00
Standardna devijacija	9,07
Minimalna dob	16
Maksimalna dob	58

Tablica 4.3. Distribucija sudionika prema operacijskom sustavu pametnog telefona

Operacijski sustav	Broj sudionika	Udio (%)
iOS	32	80
Android	8	20

5. Inercijski senzori za praćenje kretanja

5.1. Inercijski senzori

Pametni sat opremljen je inercijskim senzorima. Inercija označava svojstvo tijela da se opire promjeni stanja mirovanja ili gibanja nakon djelovanja vanjske sile, pri čemu inercijska sila nastoji vratiti tijelo u početno stanje [11]. Inercijski senzori rade upravo po ovom principu, a mjerenjem odstupanja od početnog stanja pokret se može numerički kvantificirati i opisati.

Najvažniji senzori za praćenje pokreta su akcelerometar, žiroskop i magnetometar. Skup različitih inercijskih senzora objedinjenih u jednu cjelinu naziva se inercijska mjerna jedinica (engl. *Inertial Measurement Unit*, IMU). IMU se temelji na kombinaciji akcelerometra i žiroskopa, a ponekad uključuje i magnetometar. Karakterizira ju visoka brzina odziva te otpornost na vanjske čimbenike kao što su vjetar i radio signali [11]. Jedan od glavnih izazova inercijskih senzorskih sustava su smetnje magnetskog polja u zatvorenim prostorima, koje uzrokuju netočna očitavanja magnetometra te otežavaju preciznu procjenu orijentacije i kretanja. Primjerice, u blizini lifta.

Pri prikupljanju podataka, zabilježeni su podaci akcelerometra i žiroskopa. Podaci magnetometra nisu zabilježeni.

5.2. Komponente pametnog sata

5.2.1. Akcelerometar

Akcelerometar je inercijski senzor namijenjen mjerenju ubrzanja tijela [12]. Princip rada temelji se na inercijskoj masi unutar senzora koja, zbog svoje tromosti, zaostaje za kre-

tanjem kućišta, što se detektira promjenom kapaciteta u mikro-strukturi [11]. Akcelometri mogu mjeriti statičko ubrzanje (poput gravitacije) te dinamičko ubrzanje (vibracije i pokret). Referentna vrijednost u odnosu na koju se mjeri ubrzanje jest gravitacijsko ubrzanje Zemlje, $g = 9,81 \text{ m/s}^2$ [12]. Ovisno o izvedbi, akcelometri mogu mjeriti ubrzanje duž jedne, dvije ili tri osi. U sustavima za prepoznavanje aktivnosti standardno se primjenjuje troosni akcelometar, koji omogućuje visoku preciznost.

5.2.2. Žiroskop

Žiroskop je inercijski senzor namijenjen mjerenju kutne brzine u inercijskom referentnom sustavu. Konceptualno, žiroskop funkcionira kao rotirajući kotač čija os rotacije može poprimiti bilo koji prostorni smjer [12]. Integracijom izmjerene kutne brzine, uz poznatu početnu orijentaciju kao početni uvjet, u svakom se trenutku može odrediti orijentacija sustava. Današnji pametni satovi koriste žiroskope tipa MEMS (engl. *Micro-Electro-Mechanical Systems*) žiroskope. Odlikuju se malim dimenzijama, niskom potrošnjom energije i niskom cijenom proizvodnje [4].

6. Vremenski nizovi u podacima senzora

6.1. Definicija i karakteristike vremenskih nizova

Vremenski niz predstavlja skup statističkih opažanja zabilježenih u kronološkom redoslijedu. Opažanja, koja se mogu nazivati i uzorcima ili podacima, najčešće se prikupljaju periodično unutar određenog vremenskog intervala. Važno je da vremenski intervali budu konzistentni, odnosno da podaci nisu prikupljeni nasumično ili isprekidano [13]. U okviru ovog rada vremenski nizovi se pojavljuju u obliku signala tijekom snimanja podataka pametnim satom i mobilnim telefonom.

Glavni cilj analize vremenskih nizova jest sažeti podatke, pravilno ih interpretirati te na temelju detaljne analize donijeti odgovarajuće zaključke [13]. Analizom vremenskih nizova nastoje se uočiti ponavljajući uzorci koji omogućuju predviđanje budućih vrijednosti ili klasifikaciju određenih pojava. Pametni sat bilježi pokret na način da inercijski senzor unutar pametnog sata snima i pohranjuje signale. Cilj analize je prepoznati karakterističan uzorak na temelju kojeg se određeni pokret može razlikovati od ostalih.


Jedan od osnovnih matematičkih pristupa analizi vremenskih nizova jest dekompozicija signala. Signal se može rastaviti na četiri komponente:

$$X_t = T_t + I_t + C_t + E_t \quad (6.1)$$

pri čemu X_t predstavlja zabilježeni signal, T_t trend u trenutku t , I_t sezonsku komponentu, C_t cikličku komponentu, a E_t pogrešku odnosno šum [14]. Trend predstavlja ukupni smjer kretanja podataka tijekom vremena te može biti rastući, padajući ili stabilan. Sezonska komponenta označava ponavljajući uzorak unutar određenog vremen-

skog razdoblja, primjerice dnevni ritam rada srca. Cikličke komponente predstavljaju ponavljajuće, ali nesezonske uzorke bez strogo definiranog perioda. Šum obuhvaća nepredvidive promjene koje se ne mogu objasniti ostalim komponentama modela [15].

Po određenim karakteristikama vremenskog niza možemo uočiti razlike između određenih aktivnosti te prema tome, uspješno razlučiti klase odnosno aktivnosti. Navedena vizualizacija na slici 6.1. prikazuje razlike u dinamici signala za tri novouvedena mikropokreta.



Slika 6.1. Prikaz vremenskog niza signala akcelerometra za subjekt 1653

Graf prikazuje podatke akcelerometra u trajanju od 8 sekundi za sve tri prostorne osi (x, y, z), uz pridruženu magnitudu signala izračunatu prema izrazu: $magnituda = \sqrt{x^2 + y^2 + z^2}$.

Analizom signala za aktivnost listanja sadržaja na društvenim mrežama uočava se periodičan pomak prsta, koji se u signalu očituje kao karakterističan visoki vrh (engl. *peak*) pri 2.7s i 6s. Nadalje, aktivnost grickanja noktiju pokazuje visoku razinu stohastičnosti i neredovitosti, što je očekivano, ali otežava njezino vizualno raspoznavanje u vremenskoj domeni. S druge strane, aktivnost treskanja nogom odlikuje se pravilnom periodičkom strukturom s izraženim vrhovima, što omogućuje jednostavniju detekciju. Usporedbom amplituda vidljivo je da aktivnost listanja sadržaja generira signale manjeg intenziteta u odnosu na ostale dvije aktivnosti, što je očekivano s obzirom na to da je riječ

o pokretu manjeg opsega. Po ovom primjeru se može vidjeti kako se pokreti razlikuju te kako se, uz kvalitetnu predobradu podataka i ekstrakciju značajki, može razviti robustan model sposoban za visoku preciznost.

6.2. Šum i filtriranje


S obzirom na poteškoće i ograničenja pri korištenju senzora opisana u poglavlju 3.3., uz osnovni signal može biti zahvaćen i šum. Šum je signal koji predstavlja smetnju i koji u idealnim uvjetima ne bi trebao biti prisutan. Gotovo je nemoguće dva puta reproducirati identičan signal upravo zbog šuma, pa je stoga potrebno primijeniti odgovarajuće filtre kako bi se šum što vjerodostojnije uklonio.

Općenito se razlikuju dva pristupa filtraciji signala: filtracija mijenjanjem spektra signala i filtracija propuštanjem signala kroz sustav koji se naziva filter [16]. Filtracija je postupak kojim se iz ulaznog signala $x[n]$ izdvaja željena komponenta signala $x_a[n]$, odnosno kojim se potiskuje neželjena komponenta signala $x_b[n]$ [17]. U okviru ovog rada korištena je filtracija s propuštanjem signala kroz filter.

Neki od najčešće primjenjivanih filtera u obradi signala senzora su niskopropusni (engl. *low-pass*), visokopropusni (engl. *high-pass*), pojasnopropusni (engl. *band-pass*) i pojasna brana (engl. *band-stop*) [17]. Niskopropusni filter uklanja šumove visokih frekvencija, dok visokopropusni filter uklanja komponente niskih frekvencija. Pojasnopropusni filter propušta samo frekvencije unutar određenog intervala, dok pojasna brana potiskuje frekvencije unutar zadanog područja, a propušta ostale frekvencije [17].

Za obradu senzorskih podataka primijenjen je pojasnopropusni Butterworthov filter. Njegova prednost je „maksimalno ravan“ frekvencijski odziv (engl. *maximally flat passband*), čime se izbjegava pojava neželjenih oscilacija (valova) u propusnom području koje bi mogle izobličiti amplitudu signala. Osim očuvanja izvornog oblika, filter jamči relativno linearnu faznu karakteristiku unutar propusnog opsega, što je bitno za sprječavanje vremenskog rastezanja signala.

Na slici 6.2. prikazan je utjecaj primijenjenog Butterworthovog filtra na signal akcelerometra pametnog sata po osi x . X-os prikazuje vrijeme mjerenja u sekundama, dok y-os prikazuje vrijednosti ubrzanja izmjerene akcelerometrom. Filtrirani signal (naran-




Slika 6.2. Usporedba izvornog i filtriranog signala akcelerometra po osi x za subjekt 1631

časta linija) zadržava osnovni oblik i karakteristike sirovog signala (plava linija), dok je istovremeno smanjen utjecaj visokofrekvencijskog šuma. Raspon signala je različit, pri čemu se filtrirani signal u prikazanom intervalu uglavnom kreće od približno -20 do 10 , dok se izvorni signal kreće od približno -10 do 20 .

Za određivanje granične vrijednosti (engl. *threshold*) Butterworthovog filtra, analizirana je gustoća spektralne snage (engl. *Power Spectral Density*, PSD), prikazana na slici 6.3. Za svaku aktivnost uzimaju se filtrirani podaci o magnitudi ubrzanja svih ispitanika te se potom izračunava gustoća spektralne snage (PSD). Dobivene PSD krivulje za sve aktivnosti prikazuju se na zajedničkom grafu kako bi se usporedila raspodjela energije signala po frekvencijama. Vrijednosti spektralne snage su prikazane u logaritamskom mjerilu u odnosu na frekvenciju na apscisi. Analiza grafa otkriva jasnu razliku pojedinih aktivnosti. Aktivnosti s izraženom periodičkom komponentom, poput trčanja (B) i hodanja (A), pokazuju visoku gustoću snage. S druge strane, statične aktivnosti poput sjedenja (D) ili stajanja (E), kao i neki mikro-pokreti (F-L), pozicionirani su u donjem dijelu spektra, gdje je energija signala znatno manja i bliža razini šuma.

Time je uočeno da se većina korisnih informacija o aktivnostima nalazi u frekvencijskom pojasu do $6,5$ Hz, unutar kojeg su razlike između aktivnosti najizraženije. Iznad te granične frekvencije (engl. *cutoff frequency*), spektralna snaga signala opada i poprima karakteristike pozadinskog šuma. Posebna pozornost posvećena je mikro pokretima, zbog čega je bilo nužno precizno postaviti granice filtra kako bi se očuvala njihova in-



Slika 6.3. Procjene PSD-a magnitude ubrzanja za sve aktivnosti na temelju podataka svih ispitanika

formacija, a istovremeno učinkovito uklonio šum. Pritom je trebalo pažljivo odabrati parametre kako bi se spriječilo da makro pokreti, koji imaju znatno veće amplitude, naruše analizu ovih osjetljivih podataka. Stoga je odabran pojas od 0,1 Hz do 6,5 Hz reda 4 kao optimalan za daljnju analizu. Što je red viši, to je prijelaz između propusnog područja i područja prigušenja oštiri.

7. Obrada i analiza podataka u sustavima HAR

7.1. Predobrada podataka

Predobrada je postupak kojim se neobrađeni, snimljeni podaci preoblikuju i pripremaju tako da su pogodni za učenje modela strojnog učenja. Ovaj korak izravno utječe na točnost i pouzdanost modela za prepoznavanje aktivnosti [18].

7.2. Deskriptivna analiza

U nastavku su opisani koraci predobrade podataka. Uz uklanjanje šuma (filtriranje), iz skupa podataka uklanjaju se i nedostajuće vrijednosti te zapisi nastali greškom pri snimanju, koji mogu biti posljedica kvara uređaja ili pogrešaka u prijenosu podataka [18]. Analizom korištenog skupa podataka utvrđeno je da ne sadrži nedostajuće vrijednosti.

Deskriptivnom statistikom sažimaju se najznačajniji statistički parametri svake varijable. Iz podataka se mogu izlučiti minimum, maksimum, srednja vrijednost, medijan i standardna devijacija (opisuje rasipanje podataka unutar cijelog skupa) [18]. Na temelju navedenih parametara moguće je dobiti uvid u skalu i raspon podataka za svaku varijablu.

Deskriptivnom analizom uspješno su interpretirani podaci. Za većinu statičkih aktivnosti, poput sjedenja, stajanja, tipkanja ili jedenja, srednja vrijednost magnitude akcelerometra iznosi približno $9,7 - 9,8 \text{ m/s}^2$, uz vrlo nisku standardnu devijaciju žiroskopa. Suprotno tomu, kod dinamičkih aktivnosti poput hodanja, trčanja ili penjanja stubama, standardna devijacija je znatno veća, što jasno ukazuje na intenzivnije pokrete.

7.3. Segmentacija

Segmentacija podataka postupak je kojim se vremenski kontinuirani tok podataka senzora dijeli na manje segmente ili prozore kako bi se zahvatili vremenski aspekti aktivnosti [18]. U ovom radu primijenjen je pristup klizećeg prozora (engl. *sliding window*).

Veličina klizećeg prozora definira se ovisno o trajanju i dinamičkim karakteristikama promatrane aktivnosti. Pri odabiru parametara vodilo se računa o tome da veličina prozora obuhvati jedan do dva ciklusa pokreta te da bude adekvatna i za makro i za mikro pokrete. Stoga je odabran fiksni vremenski prozor trajanja 10 sekundi bez preklapanja prozora. Ovako definiran interval predstavlja optimalan kompromis jer je dovoljno dug da zahvati više ponavljanja kod aktivnosti s cikličkim pokretima, a istovremeno dovoljno kratak da osigura zadovoljavajući odziv klasifikacijskog modela, omogućujući generiranje predikcije svakih 10 sekundi.

7.4. Ekstrakcija značajki

Ekstrakcijom značajki iz podataka dobiva se skup značajki koje opisuju različita svojstva signala, pri čemu se selekcijom odabiru one najinformativnije, odnosno one koje najbolje opisuju i diskriminiraju promatrane aktivnosti. Ispravan izbor značajki koje se računaju vrlo je važan za uspjeh detekcije i klasifikacije [19]. Značajke se mogu podijeliti na značajke u vremenskoj domeni (engl. *time-domain features*), frekvencijskoj domeni (engl. *frequency-domain features*), vremensko-frekvencijskoj domeni (engl. *time-frequency domain features*), heurističke značajke (engl. *heuristic features*) te domenske značajke (engl. *domain-specific features*) [19].

Izdvojen je sveobuhvatan skup značajki, iz kojeg su kroz nekoliko koraka odabrane najrelevantnije značajke. Najprije su uklonjene značajke s nultom varijansom, odnosno značajke koje ne pružaju informaciju o razlikama između uzoraka. Zatim su na temelju važnosti značajki i međusobne korelacije uklonjene redundantne značajke. Na preostalom skupu provedena je rekurzivna eliminacija značajki uz unakrsnu validaciju (engl. *Recursive Feature Elimination with Cross-Validation*, RFECV), pri čemu je kao klasifikacijski model korišten LightGBM. Ovim postupkom iterativno su uklanjane manje relevantne značajke, a kvaliteta pojedinih podskupova značajki procijenjena je pomoću

unakrsne validacije. Odabrane značajke i njihova pripadnost pojedinim kategorijama prikazane su u nastavku.

U vremenskoj domeni za svaki vremenski prozor i pojedini kanal signala izračunavaju se srednja vrijednost, minimum, maksimum, koeficijent asimetričnosti (engl. *skewness*), energija signala, interkvartilni raspon (engl. *interquartile range*, IQR) te srednja apsolutna razlika susjednih uzoraka (engl. *mean absolute difference*, AAD). Za nemođificirane kanale magnitude dodatno se izračunava medijan. Srednja vrijednost opisuje prosječnu razinu signala, dok minimum i maksimum određuju njegov raspon unutar promatranog prozora. Koeficijent asimetričnosti mjeri stupanj asimetrije raspodjele podataka oko srednje vrijednosti, dok interkvartilni raspon opisuje raspršenost središnjih 50% vrijednosti [20]. Srednja apsolutna razlika opisuje prosječnu promjenu vrijednosti između uzastopnih uzoraka. Energija signala računa se kao zbroj kvadrata svih vrijednosti signala unutar promatranog vremenskog prozora, podijeljen s brojem uzoraka [20]. Ova značajka služi kao indikator ukupne snage signala, pri čemu veće vrijednosti energije ukazuju na intenzivnije pokrete s većim amplitudama, dok niske vrijednosti energije karakteriziraju statičke aktivnosti ili stanja mirovanja.

Dodatno, primjenom brze Fourierove transformacije (engl. *Fast Fourier Transform*, FFT) signal se prevodi iz vremenske u frekvencijsku domenu, čime se omogućuje analiza spektralne strukture signala [20]. Iz dobivenog spektra amplituda izračunavaju se standardna devijacija amplituda i dominantna frekvencija. Dominantna frekvencija predstavlja frekvenciju s najvećom amplitudom u spektru i ukazuje na osnovnu ritmičnost aktivnosti [20].

Za opis dinamike filtriranih signala izračunavaju se stopa prelaska kroz nulu (engl. *zero-crossing rate*, ZCR) te autokorelacija za pomake od jednog, dva i tri uzorka. ZCR opisuje učestalost promjene predznaka signala u odnosu na njegovu medijalnu vrijednost, dok autokorelacija opisuje sličnost signala s njegovom vremenski pomaknutom verzijom [14]. Kako bi se opisala povezanost između pojedinih osi troosnih senzora, izračunavaju se koeficijenti korelacije (engl. *correlation coefficients*) između svih parova osi, odnosno XY, XZ i YZ. Dodatno se izračunava magnituda signala (engl. *signal magnitude*), definirana kao Euklidska norma vrijednosti po svim trima osima. Na temelju magnitude izračunavaju se njezina standardna devijacija i srednja apsolutna razlika, čime se opi-

suju varijabilnost i promjene intenziteta gibanja neovisno o pojedinačnoj osi senzora. Za izvorne troosne signale dodatno se izračunavaju signal *magnitude area* (SMA), implementiran kao prosječna magnituda signala, te kutovi nagiba *pitch* i *roll*, koji opisuju orijentaciju senzora u prostoru.

Popis svih korištenih značajki i pripadajućih formula prikazan je u tablici 7.1., sukladno njihovoj implementaciji u programskom kodu.

7.5. Podjela podataka i transformacija

Podaci su podijeljeni na skupove za učenje i testiranje u omjeru 80:20 prema subjektu (engl. *user-independent split*). Ovakav pristup sprječava curenje podataka (engl. *data leakage*) i osigurava da model prepozna aktivnosti općenito, a ne specifične pokrete pojedinog korisnika. Nakon podjele, primijenjena je standardizacija podataka z-skorom (engl. *StandardScaler*) [18]. Time se osigurava da su značajke prikupljene s različitih senzora i uređaja, u ovom slučaju s pametnog telefona i pametnog sata, dovedene na istu skalu. Tako se izbjegava pristranost prema bilo kojem skupu podataka i svim se značajkama pridaje podjednaka težina.

Prilikom obrade razmatrana je mogućnost primjene analize glavnih komponenti (engl. *Principal Component Analysis*, PCA) za redukciju dimenzionalnosti (engl. *dimensionality reduction*). No ova metoda ima dva rizika. Prvenstveno, gubi se izravna interpretabilnost jer izvorne značajke postaju apstraktne komponente, što otežava analizu pogrešaka modela. Drugi rizik jest da PCA prioritizira komponente s velikom varijancom. Zbog toga se suptilni mikro-pokreti, koji imaju malu varijancu, mogu nehotice potisnuti u odnosu na intenzivnije makro-pokrete. S druge strane, model postaje robusniji ukoliko se primjeni PCA. Usporedit će se model sa i bez primjene PCA.

Tablica 7.1. Definicije i formule značajki korištenih u radu sukladno implementaciji u programskom kodu

Kategorija	Značajka	Formula
Vremenska domena	Srednja vrijednost	$\mu = \frac{1}{N} \sum_{i=1}^N x_i$
	Minimum	$x_{\min} = \min(x_1, \dots, x_N)$
	Maksimum	$x_{\max} = \max(x_1, \dots, x_N)$
	Asimetričnost	$\text{skew}(x) = \frac{1}{N} \sum_{i=1}^N \left(\frac{x_i - \mu}{\sigma} \right)^3$
	Energija	$E = \frac{1}{N} \sum_{i=1}^N x_i^2$
	Interkvartilni raspon (IQR)	$IQR = Q_3 - Q_1$
	Srednja apsolutna razlika (AAD)	$AAD = \frac{1}{N-1} \sum_{i=1}^{N-1} x_{i+1} - x_i $
Frekvencijska domena	Std. dev. FFT amplituda	$\sigma_A = \sqrt{\frac{1}{K} \sum_{k=1}^K (A_k - \bar{A})^2}$
	Dominantna frekvencija	$f_{\text{dom}} = f_{k^*}, \quad k^* = \arg \max_k A_k$
Dinamičke značajke	Stopa prelaska kroz nulu (ZCR)	$ZCR = \frac{1}{N} \sum_{i=1}^{N-1} \mathbb{1}[\text{sign}(x_i - m) \neq \text{sign}(x_{i+1} - m)]$
	Autokorelacija	$\rho_k = \frac{\sum_{i=1}^{N-k} (x_i - \mu)(x_{i+k} - \mu)}{\sum_{i=1}^N (x_i - \mu)^2}, \quad k \in \{1, 2, 3\}$
Korelacijske značajke	Korelacija	$\rho_k = \text{corr}(x_1, \dots, x_{N-k}; x_{k+1}, \dots, x_N), \quad k \in \{1, 2, 3\}$
Magnituda i orijentacija	Signal magnitude	$m_i = \sqrt{x_i^2 + y_i^2 + z_i^2}$
	Std. dev. magnitude	$\sigma_m = \sqrt{\frac{1}{N} \sum_{i=1}^N (m_i - \bar{m})^2}$
	AAD magnitude	$AAD_m = \frac{1}{N-1} \sum_{i=1}^{N-1} m_{i+1} - m_i $
	Signal magnitude area (SMA)	$SMA = \frac{1}{N} \sum_{i=1}^N m_i$
	Pitch	$\text{pitch} = \frac{180}{\pi} \arctan 2 \left(\bar{y}, \sqrt{\bar{x}^2 + \bar{z}^2} \right)$
	Roll	$\text{roll} = \frac{180}{\pi} \arctan 2 (-\bar{x}, \bar{z})$

8. Klasifikacijski modeli i učenje

U okviru ovog rada razmatraju se dva tipa klasifikacijskih modela: tradicionalni algoritmi strojnog učenja te modeli dubokog učenja. Od klasičnih algoritama nadziranog učenja primijenjenit će se stablo odluke, slučajna šuma, SVM, kNN i LightGBM, dok su od modela dubokog učenja razmatrani jednodimenzionalni CNN i RNN. Odabir navedenih modela temelji se na rezultatima i preporukama iz istraživanja [19].

Stablo odluke vrsta je klasičnog algoritma strojnog učenja koji podatke klasificira u jednu od promatranih aktivnosti na temelju jednostavnih pravila odlučivanja [18]. Naziva se stablom odluke jer ima strukturu nalik stablu, u kojoj svaki čvor predstavlja određenu značajku, a svaki list označava klasu. Na temelju unaprijed definiranih pragova određuje se kojom se granom stabla nastavlja klasifikacija. Prednost ovog algoritma jest njegova jednostavnost i interpretabilnost, no nedostatak je sklonost prenaučivosti, osobito u slučaju podataka visoke složenosti.

Slučajna šuma (engl. *Random Forest*) model je koji kombinira više stabala odluke s ciljem poboljšanja performansi i smanjenja prenaučivosti [18]. Svako stablo uči na drugom podskupu podataka s nasumično odabranim podskupom značajki. Ovaj model otporniji je na šum i visokodimenzionalne podatke u usporedbi s pojedinačnim stablom odluke, no računalno je zahtjevniji, što je relevantna stavka s obzirom da proučavamo sustave koji provode klasifikaciju u stvarnom vremenu.

Metoda potpornih vektora (engl. *Support Vector Machine*, SVM) algoritam je nadziranog učenja čiji je cilj pronalazak optimalne hiperravnine koja razdvaja različite klase maksimiziranjem razmaka (engl. *margin*) između njih [21]. Algoritam koristi tzv. jezgri trik kako bi podatke koji nisu linearno odvojivi u izvornom prostoru preslikao u prostor viših dimenzija, gdje je pronalazak linearne granice razdvajanja znatno jednos-

tavniji.

Algoritam k -najbližih susjeda (engl. *K-Nearest Neighbors*, kNN) algoritam je nadziranog učenja koji predikciju donosi na temelju većinske klasne oznake k najbližih susjeda u prostoru značajki. Hiperparametar k određuje složenost modela, a njegova vrijednost predstavlja broj najbližih susjeda [22].

LightGBM [23] je napredni algoritam temeljen na gradijentnom pojačanju (engl. *Gradient Boosting*). Dok većina algoritama gradi stablo razinu po razinu (engl. *level-wise*), LightGBM koristi strategiju rasta po listovima (engl. *leaf-wise growth*). On u svakom koraku dijeli onaj list koji donosi najveće smanjenje pogreške, što mu omogućuje bržu konvergenciju uz manju potrošnju memorije. Glavna prednost mu je učinkovitost pri radu s velikim skupovima podataka.

Rekurentne neuronske mreže (engl. *Recurrent Neural Networks*, RNN) su modeli dubokog učenja oblikovani za obradu sekvencijalnih podataka zadržavanjem informacija iz prethodnih koraka [24]. Temeljna procesna jedinica je rekurentna jedinica (engl. *recurrent unit*) koja održava skriveno stanje (engl. *hidden state*), djelujući kao "memorija" mreže. Povratnom vezom skrivenog stanja, mreže mogu "zapamtiti" podatke iz prijašnjih koraka i uhvatiti ovisnosti kroz vrijeme, što ih čini pogodnim izborom za prepoznavanje aktivnosti [24].

Konvolucijske neuronske mreže (engl. *Convolutional Neural Network*, CNN) neuronske su mreže poznate po učinkovitosti u obradi vizualnih podataka [18]. U kontekstu HAR-a primjenjuju se jednodimenzionalne CNN arhitekture (1D CNN) izravno na vremenske nizove podataka senzora, pri čemu konvolucijski filtri automatski detektiraju relevantne lokalne uzorke u signalu.

Za tradicionalne modele kao ulazni podaci koriste se značajke ekstrahirane iz prethodno obrađenih vremenskih nizova, dok se modeli dubokog učenja, odnosno CNN i RNN, izravno primjenjuju na vremenske nizove nakon predobrade. Na temelju ulaznih podataka modeli uče obrasce potrebne za klasifikaciju te svakom uzorku dodjeljuju odgovarajuću oznaku. Izlaz modela predstavlja distribuciju vjerojatnosti nad K klasa, koje u ovom slučaju odgovaraju pojedinim aktivnostima.

9. Aktivno učenje

Jedan od glavnih izazova u klasifikaciji ljudskih pokreta putem vremenskih nizova jest njihova visoka dimenzionalnost i složenost distribucija. Navedeni problem osobito dolazi do izražaja kod raspoznavanja mikro-pokreta, gdje je signal niske amplitude. Kako bi se optimirao proces učenja i smanjila potreba za ekstenzivnim označenim skupovima podataka, u ovom radu primjenjuje se strategija aktivnog učenja (engl. *Active Learning*) [25].

Algoritamski postupak temelji se na iterativnom modelu učenja. Inicijalno, klasički model uči na ograničenom, nasumično odabranom podskupu podataka. U svakoj sljedećoj iteraciji model predviđa vjerojatnosti pripadnosti klasama za instance iz neoznačenog skupa podataka [25]. Na temelju tih vjerojatnosti izračunava se entropija predikcije, pri čemu veća vrijednost entropije označava veću nesigurnost modela. Odabire se određeni broj instanci s najvećim vrijednostima entropije, odnosno onih za koje je model najnesigurniji u svoju predikciju. Odabrane instance zatim se premještaju iz neoznačenog skupa u označeni skup te se model ponovno uči na proširenom skupu podataka. Proces se u ovom radu ponavlja kroz unaprijed definiran broj iteracija.

Aktivno učenje primijenit će se na sve prethodno navedene modele. Primjena aktivnog učenja u ovom radu omogućuje izravnu usporedbu s nadziranim učenjem (engl. *supervised learning*). Dok klasični pristupi zahtijevaju cjelovite, unaprijed označene skupove podataka, aktivno učenje omogućuje modelu da se fokusira na granične i informativno bogate uzorke koji najbolje opisuju karakteristike pokreta.

10. Rezultati

Analizom skupa podataka potvrđeno je da ne postoje nedostajuće vrijednosti. Tijekom učenja modela isprobavani su različiti skupovi podataka odnosno varijante skupova. S obzirom na to da skup podataka WISDM sadrži podatke s pametnog telefona i sata, za prvu varijantu provedena je senzorska fuzija horizontalnim spajanjem podataka. To znači da su uzorci akcelerometra i žiroskopa spojeni prema ispitaniku, aktivnosti i indeksu uzorka, tako da podaci koji pripadaju istom uzorku čine jedan redak. Podaci akcelerometra i žiroskopa su snimani simultano, što osigurava uniformnost podataka. Druga varijanta skupa podataka temelji se isključivo na podacima pametnog telefona, dok se treća odnosi isključivo na podatke pametnog sata. Četvrta varijanta obuhvaća podatke pametnog sata iz skupa podataka WISDM s proširenim skupom od tri nove aktivnosti. Za svaki su navedeni skup podataka isprobani svi prethodno definirani klasifikacijski modeli.

Filtracija podataka provedena je Butterworthovim filtrom u rasponu od 0,1 do 6,5 Hz, nakon čega je uslijedila segmentacija (engl. *windowing*) s veličinom prozora od 200 uzoraka bez preklapanja. Na četvrtoj varijanti skupa podataka, odnosno podaci pametnog sata iz skupa podataka WISDM i proširenim aktivnostima, je fokus istraživanja. Za tu varijantu, nakon segmentacije dobiven je niz oznaka oblika (17392,). Podjela na skupove za učenje i testiranje provedena je u omjeru 80:20 slučajno prema subjektu. Hiperparametri tradicionalnih i modela dubokog učenja optimirani su na skupu za učenje primjenom unakrsne validacije po ispitanicima. Za tradicionalne modele korištena je stratificirana unakrsna validacija s pet presjeka i slučajna pretraga 20 kombinacija hiperparametara, dok je za modele dubokog učenja ispitano 10 kombinacija hiperparametara uz pet presjeka unakrsne validacije. Dobivene najbolje vrijednosti hiperparametara prikazane su u nastavku.

Tablica 10.1. Hiperparametri tradicionalnih modela.

Model	Ključni hiperparametri
Decision Tree	max_depth=20, min_samples_split=5, min_samples_leaf=10
Random Forest	n_estimators=200, max_depth=40, min_samples_split=5, min_samples_leaf=2
SVM (RBF)	C=10, kernel=rbf
kNN	n_neighbors=7, weights=distance, metric=manhattan
LightGBM	n_estimators=300, num_leaves=127, learning_rate=0.1, min_child_samples=30, subsample=0.8

Tablica 10.2. Arhitektura dubokih modela (1D-CNN i RNN). Ulaz: $(N, 200, 16)$, gdje je N broj vremenskih prozora, 200 broj uzoraka po prozoru, a 16 broj senzorskih kanala.

Sloj	1D-CNN	RNN
1	Conv1D(128, $k=5$, ReLU, padding=same)	SimpleRNN(64, tanh)
2	MaxPooling1D($p=2$)	Dense(64, ReLU)
3	Conv1D(128, $k=5$, ReLU, padding=same)	Dropout(0.3)
4	MaxPooling1D($p=2$)	Dense(C , softmax)
5	Flatten	—
6	Dense(128, ReLU)	—
7	Dropout(0.5)	—
8	Dense(C , softmax)	—

Tablica 10.3. Parametri učenja dubokih modela (zajednički za 1D-CNN i RNN). Optimizator Adam koristi zadane Keras postavke.

Parametar	Vrijednost
Funkcija gubitka	kategorička cross-entropija
Broj epoha	15
Veličina batcha	64
Kodiranje oznaka	one-hot (to_categorical)

10.1. Opseg evaluacije i glavni skup podataka

S obzirom da je glavni cilj ostvariti uspješno raspoznavanje ljudskog pokreta s fokusom na mikro-pokrete, glavni skup podataka za analizu rezultata je četvrta varijanta: *pametni sat + proširene aktivnosti* (podaci s pametnog sata iz skupa podataka WISDM uz tri dodatne mikro-aktivnosti: *scrolling*, *nail_biting* i *leg_tremor*).

Ostale varijante (podaci s mobilnog telefona + podaci s pametnog sata, isključivo podaci s pametnog sata, isključivo podaci s mobilnog telefona) korišteni su radi usporedbe performansa modela. Uz to, na istoj glavnoj, četvrtoj varijanti skupa podataka proveden je dodatni eksperiment kako bi se procijenio utjecaj korištenja analize glavnih komponenti (engl. *Principal Component Analysis*, PCA). U nastavku poglavlja prvo se uspoređuje glavna (četvrta) varijanta skupa podataka s ostalim varijantama, zatim se analiziraju rezultati na glavnom skupu podataka, izvedba aktivnog učenja te na kraju utjecaj metode PCA.

10.2. Usporedba skupova podataka

Prije detaljne analize glavnog skupa podataka, provedena je usporedna evaluacija nad svim definiranim varijantama podataka. Tablica 10.4. prikazuje najbolju točnost po skupu za reprezentativne modele. S obzirom na to da su klase uravnotežene, točnost se ovdje smatra pouzdanim mjerilom usporedbe, dok bi u slučaju neuravnoteženih skupova primarna metrika evaluacije bila F1-mjera.

Tablica 10.4. Usporedba najboljih modela po skupu podataka (točnost na testnom skupu).

Skup podataka	Klasični (najbolji)	Acc.	DL (najbolji)	Acc.
Telefon + sat	LightGBM	0,771	1D-CNN	0,690
Samo telefon	Random Forest	0,423	1D-CNN	0,299
Samo sat	SVM	0,748	1D-CNN	0,685
Sat + proširene aktivnosti	LightGBM	0,736	1D-CNN	0,661
Mikro-pokreti (3 klase)	Random Forest	0,888	RNN	0,810

Iz tablice proizlazi da učenjem modela isključivo s podacima s mobilnog telefona znatno degradiraju performanse (točnost 42%). Takav pad je očekivan jer je telefon tijekom snimanja (skupa podataka WISDM) smješten u džepu subjekta, pa akcelerometar i žiroskop uglavnom bilježe translaciju tijela, a ne specifične pokrete ruku. Usporedba va-

rijante *samo sat* (75%) i *telefon + sat* (77%) pokazuje da fuzija senzora donosi blago poboljšanje. Prošireni skup (21 klasa umjesto 18) predstavlja najzahtjevniji scenarij klasifikacije, što se vidi u blagom padu točnosti u odnosu na osnovni skup temeljen na podacima pametnog sata iz skupa WISDM. Pad je posljedica uvođenja dodatnih mikro-pokreta, no modeli i dalje postižu dobre rezultate.

Kad model uči isključivo na tri mikro-pokreta, točnost raste do 88%. To nije primarni cilj rada, ali potvrđuje da su mikro-pokreti bez makro-pokreta dobro razdvojivi u prostoru značajki.

10.3. Rezultati na glavnom skupu podataka

Na glavnom skupu (pametni sat + proširene aktivnosti) testirano je pet klasičnih i boosting modela i dvije arhitekture dubokog učenja. Tablica 10.5. sažima ukupne performanse.

Tablica 10.5. Performanse modela na fokusnom skupu podataka.

Model	Točnost	Vrijeme učenja [s]
<i>Klasični i boosting modeli</i>		
Decision Tree	0,617	3.27
Random Forest	0,718	2.27
SVM (RBF)	0,726	18.01
kNN	0,713	<0.01
LightGBM	0,736	28.01
<i>Duboko učenje</i>		
1D-CNN	0,661	54.57
RNN	0,436	32.65

Najbolje rezultate među klasičnim modelima ostvaruje LightGBM, s točnošću od 0,736, dok ga slijede SVM (0,726), Random Forest (0,718) i kNN (0,713). Među modelima dubokog učenja najbolji rezultat ostvaruje 1D-CNN, s točnošću od 0,661, no njegov je rezultat i dalje slabiji u odnosu na klasične modele. RNN ostvaruje uvjerljivo najlošiji rezultat, s točnošću od svega 0,436. Razlika između najboljeg tradicionalnog i najboljeg modela dubokog učenja očituje se, osim u točnosti, i u vremenu učenja, koje je znatno duže kod modela dubokog učenja. kNN se uči za manje od 0,01 s, Random Forest za 2,27 s, a SVM za približno 18 s, dok 1D-CNN zahtijeva oko 52 s. Stoga klasični modeli, osobito kNN i Random Forest, predstavljaju pogodniji izbor za praktičnu primjenu u stvarnom

vremenu kada je važno kratko vrijeme učenja, dok 1D-CNN ima smisla kada je prioritet maksimalna točnost, bez obzira na vrijeme učenja.

10.3.1. Analiza po klasama aktivnosti

Detaljnija analiza matrice performansi (preciznost, odziv, mjera F1) pokazuje da modeli ne griješe ravnomjerno između aktivnosti. Mjera F1 općenito je niža kod kategorija koje obuhvaćaju mikro-pokrete.

Complete Performance Matrix: LightGBM				
	precision	recall	f1-score	support
Catch	0.93	0.77	0.84	228
Chips	0.60	0.45	0.52	241
Clapping	0.96	0.77	0.86	241
Dribbling	0.87	0.71	0.78	241
Drinking	0.56	0.58	0.57	250
Folding	0.76	0.82	0.79	240
Jogging	0.92	1.00	0.96	241
Kicking	0.89	0.91	0.90	240
Leg_Tremor	1.00	1.00	1.00	113
Nail_Biting	0.87	0.91	0.89	113
Pasta	0.56	0.67	0.61	240
Sandwich	0.27	0.34	0.30	220
Scrolling	0.90	0.85	0.88	108
Sitting	0.44	0.82	0.58	241
Soup	0.78	0.52	0.63	241
Stairs	0.89	0.82	0.85	219
Standing	0.66	0.79	0.72	242
Teeth	0.85	0.89	0.87	241
Typing	0.89	0.63	0.74	240
Walking	0.84	0.73	0.78	241
Writing	0.85	0.73	0.79	241
accuracy			0.74	4622
macro avg	0.78	0.75	0.75	4622
weighted avg	0.76	0.74	0.74	4622

Slika 10.1. Matrica performansi po aktivnosti

Kao što je prikazano na slici 10.1., aktivnosti povezane s konzumacijom hrane (*sandwich*, *chips*, *pasta*) bilježe najniže F1-mjere. To je očekivano jer te aktivnosti dijele sličan kinematički kontekst (pokreti ruke prema licu i ustima) te imaju kratku amplitudu, što otežava njihovo razlikovanje. S druge strane, aktivnosti poput *leg_tremor* (F1-mjera 1,00) i *scrolling* (F1-mjera 0,88) postižu visoku točnost, prvenstveno zbog prisutnosti specifičnih frekvencijskih uzoraka i cikličkih ponavljanja.

Ipak, značajna razlika između preciznosti i odziva kod određenih klasa, poput *Sandwich* (0,27 / 0,34) i *Sitting* (0,44 / 0,82), ukazuje na problem preklapanja klasa unutar prostora značajki. Dok klase s izraženim cikličkim obrascima poput trčanje (0,92 / 1,00)

postiću izvrsnu separabilnost, mikro-pokreti vezani uz hranu zahtijevaju dodatne senzorske podatke kako bi se smanjila stopa lažno pozitivnih klasifikacija.

Za interpretaciju performansi modela na klasama različite zastupljenosti korištene su makro i ponderirana (engl. *weighted*) F1-mjera. Makro prosjek izračunava aritmetičku sredinu F1-mjera svih klasa, tretirajući svaku klasu jednako, bez obzira na broj primjera u njima. Nasuprot tome, ponderirani prosjek izračunava srednju vrijednost uzimajući u obzir broj uzoraka po klasi (support), čime se daje veća važnost klasama koje su u skupu podataka zastupljenije. U analiziranom modelu, makro F1-mjera (0,75) i ponderirana F1-mjera (0,74) postižu vrlo slične vrijednosti, što je očekivano s obzirom na to da je skup podataka balansiran, odnosno da su sve klase jednako zastupljene.

10.4. Rezultati aktivnog učenja

Isprobano je i aktivno učenje nad istim modelima. Inicijalno je izabrano slučajnih 10% označenih podataka za učenje. Tablica 10.6. uspoređuje modele s najvišom točnošću među varijantama skupa podataka postignutu aktivnim učenjem. Analiza pokazuje da

Tablica 10.6. Usporedba punog nadzora i aktivnog učenja po skupu podataka.

Skup podataka	Puni nadzor	Acc.	AL (najbolji)	Acc.
Telefon + sat	LightGBM	0,771	Random Forest	0,781
Samo telefon	Random Forest	0,423	Random Forest	0,401
Samo sat	SVM	0,748	SVM	0,746
Sat + proširene aktivnosti	LightGBM	0,736	LightGBM	0,725
Mikropokreti (3 klase)	Random Forest	0,888	Random Forest	0,874

aktivno učenje *ne* poboljšava cjelokupni proces klasifikacije. U većini slučajeva aktivno učenje postiže točnost blisku, ali ne i bolju od modela učenom na cijelom označenom skupu.

Važniji doprinos aktivnog učenja nije toliko u točnosti, koliko u krivulji učenja. Već nakon nekoliko iteracija modeli postižu znatni dio performansi cijelog skupa. Na primjer, za glavnu varijantu, LightGBM na iteraciji 0 (10% podataka) postiže 0,672, a na iteraciji 10 (60% podataka) 0,725, što predstavlja približno 95% performansi nadziranog učenja uz 40% manje označavanja. Stoga aktivno učenje ima smisla u scenarijima gdje je ručno označavanje skupo ili sporo, ali ne kao zamjena za nadzirano učenje kada su svi podaci za učenje već dostupni.

10.5. Utjecaj PCA redukcije

Kako bi se procijenio utjecaj analize glavnih komponenti (PCA), uspoređeni su rezultati na istom skupu sa i bez redukcije dimenzionalnosti.

Tablica 10.7. Usporedba performansi sa i bez PCA (sat + proširene aktivnosti).

Model	Bez PCA	S PCA
Decision Tree	0,617	0,555
Random Forest	0,718	0,683
SVM	0,726	0,697
kNN	0,713	0,679
LightGBM	0,736	0,697
1D-CNN	0,661	0,648
RNN	0,436	0,426

Primjena PCA redukcije, uz zadržavanje 95 % objašnjene varijance, rezultirala je blagim padom točnosti kod svih testiranih modela, pri čemu se smanjenje kreće u rasponu od 1 % do 6,2 %. Najizraženiji pad točnosti zabilježen je kod modela Decision Tree.

Unatoč postignutom ubrzanju procesa učenja i potencijalnom smanjenju rizika od prenaučenosti (overfitting), rezultati pokazuju da PCA u ovom slučaju ne doprinosi povećanju preciznosti klasifikacije. Stoga se za potrebe detekcije mikro-pokreta u okviru ovog istraživanja učenje modela na punom skupu značajki pokazuje kao optimalan pristup.

11. Diskusija

Rezultat ostvaren u ovom radu, accuracy od 77,11%, uspoređen je s rezultatima odabranih istraživanja na skupu WISDM prikazanim u tablici 11.1. Ostvareni rezultat viši je od rezultata Slothowera [26], koji je na svih 18 aktivnosti ostvario accuracy od 70,47%, dok je niži od rezultata ostalih navedenih istraživanja.

Rezultate, međutim, nije moguće izravno uspoređivati bez uzimanja u obzir razlika u broju aktivnosti, korištenim senzorima i primijenjenim modelima. Posebno je važno istaknuti da Chen et al. [28], Chrissi2802 [29] i Hossain et al. [30] koriste samo šest aktivnosti iz skupa WISDM, za razliku od pristupa u ovom radu, u kojem se razmatra svih 18 izvornih aktivnosti. Veći broj klasa povećava složenost klasifikacijskog problema, osobito zbog mogućnosti preklapanja između aktivnosti sa sličnim obrascima gibanja. Stoga se njihove accuracy vrijednosti od 92,1, %, 95,03, % i 64% ne mogu izravno usporediti s rezultatom ovog rada.

Razlike u rezultatima mogu se objasniti i složenošću korištenih modela. Primjerice, Tan et al. [31] koriste hibridni model CNN+BiGRU sa SLFN-om i RELM-om, čime se omogućuje modeliranje složenijih prostornih i vremenskih obrazaca. U ovom radu model s najboljom izvedbom je LightGBM, koji predstavlja jednostavniji pristup.

Prednost primijenjenog pristupa je i korištenje podataka s pametnog telefona i pametnog sata, čime se povećava količina dostupnih informacija o aktivnosti korisnika. S druge strane, kombiniranje više senzorskih izvora povećava broj ulaznih značajki i može otežati proces klasifikacije. Sljedeći korak bio bi ispitati složenije arhitekture modela, kako bi se utvrdilo mogu li dodatno poboljšati rezultate klasifikacije.

Tablica 11.1. Usporedba rezultata odabranih istraživanja na skupu WISDM

Rad	Najbolji model i rezultat
Benavidez & McCreight [27]	LSTM na podacima pametnog sata — accuracy 79 %
Chen et al. [28]	LSTM na WISDM (6 aktivnosti) — accuracy 92,1 %
Slothower [26]	Random Forest na 18 aktivnosti (WISDM) — accuracy 70,47 %
Chrissi2802 (Kaggle) [29]	Big GRU na 6 aktivnosti (WISDM) — accuracy 95,03 %
Hossain et al. [30]	Random Forest na 6 aktivnosti (WISDM) — accuracy $\approx$ 64 %
Tan et al. [31]	Hybrid CNN+BiGRU + SLFN with RELM — accuracy 98,2 %
Ovaj rad	LightGBM na podacima pametnog telefona i pametnog sata — accuracy 77,11 %

12. Zaključak

U ovom radu istraženo je automatsko raspoznavanje ljudskih aktivnosti s naglaskom na mikro-pokrete, koristeći podatke s pametnog sata iz skupa podataka WISDM proširenog s tri dodatne aktivnosti (*scrolling*, *nail_biting*, *leg_tremor*). Cjelokupni postupak obuhvaća učitavanje i spajanje senzorskih signala, filtraciju, segmentaciju, ekstrakciju značajki te evaluaciju tradicionalnih i dubokih modela.

Glavni doprinos rada je sustavna usporedba različitih varijanti skupa podataka. Najbolja izvedba ostvarena je na varijanti *Telefon + sat*, s točnošću od 0,771. Pametni sat prikladniji je izvor podataka za prepoznavanje finih pokreta nego mobilni telefon, čija točnost pada na 42%. Za glavni skup odnosno skup *Sat + proširene aktivnosti*, najbolji rezultat ostvario je model LightGBM s točnošću od 0,736. Razlike između tradicionalnih i dubokih modela najviše se očituju u vremenu učenja. Stoga se modeli poput LightGBM-a, SVM-a i Random Foresta mogu smatrati prikladnim izborom za primjene u stvarnom vremenu, gdje su uz točnost važni i računalna složenost te vrijeme izvođenja.

Detaljnija analiza po klasama pokazala je da modeli imaju lošiju izvedbu za mikro-pokrete. Aktivno učenje je primjenjeno te ga je najbolje koristiti u situacijama gdje je ručno označavanje skupo ili sporo, ali ne kao zamjena za nadzirano učenje kada su svi podaci već dostupni. Dodatni eksperiment s PCA redukcijom pokazao je blagi pad točnosti za sve testirane modele (1-6,2%). S obzirom da je cilj imati što višu točnost za raspoznavanje pokreta, za krajnji model preporučuje se učenje bez PCA.

Za nastavak istraživanja predlaže se prikupljanje raznolikijeg skupa mikro-pokreta radi proširenja baze podataka. Nadalje, može se isprobati integracija razvijenog modela s pametnim satom radi evaluacije sustava u stvarnim uvjetima. Moguće je ispitati složenije arhitekture dubokog učenja kako bi se izvedbe modela poboljšale.

Literatura

- [1] G. M. Weiss, “Wisdsm smartphone and smartwatch activity and biometrics dataset”, UCI Machine Learning Repository, 2019., pristupljeno: 20.2.2026. <https://doi.org/10.24432/C5HK59>
- [2] M. Rani i M. Kumar, “Human activity recognition (HAR): techniques, applications, and future directions”, *International Journal of Data Science and Analytics*, sv. 22, br. 73, 2026., pristupljeno: 1.5.2026. <https://doi.org/10.1007/s41060-026-01042-8>
- [3] M. H. Arshad, M. Bilal, i A. Gani, “Human activity recognition: Review, taxonomy and open challenges”, *Sensors*, sv. 22, br. 17, str. 6463, 2022., pristupljeno: 1.5.2026. <https://doi.org/10.3390/s22176463>
- [4] T. Seel, M. Kok, i R. S. McGinnis, “Inertial sensors — applications and challenges in a nutshell”, *Sensors*, sv. 20, br. 21, str. 6221, 2020., pristupljeno: 28.4.2026. <https://doi.org/10.3390/s20216221>
- [5] I. Lamaakal, C. Yahyati, Y. Maleh, K. El Makkaoui, I. Ouahbi, A. A. Abd El-Latif, M. Zomorodi, i B. Abd El-Rahiem, “A tiny inertial transformer for human activity recognition via multimodal knowledge distillation and explainable ai”, *Scientific Reports*, sv. 15, br. 1, str. 16401, 2025. <https://doi.org/10.1038/s41598-025-26297-2>
- [6] A. Pantelopoulos i N. Bourbakis, “A survey on wearable sensor-based systems for health monitoring and prognosis”, *IEEE Transactions on Systems, Man, and Cybernetics*, 2010., pristupljeno: 23.4.2026. [Mrežno]. Adresa: https://web.archive.org/web/20170829235246id_/http://engold.ui.ac.ir/~mahnam/IBME/Research/wearable%20medical%20devices.pdf

- [7] D. I. Fotiadis, C. Glaros, i A. Likas, “Wearable Medical Devices”, str. 3816–3827, 2006. <https://doi.org/10.1002/9780471740360.ebs1326>
- [8] H. S. Saad, J. F. W. Zaki, i M. M. Abdelsalam, “Employing of machine learning and wearable devices in healthcare system: tasks and challenges”, *Neural Computing and Applications*, sv. 36, str. 17 829–17 849, 2024. <https://doi.org/10.1007/s00521-024-10197-z>
- [9] M. Javaid, A. Haleem, S. Rab, R. Pratap Singh, i R. Suman, “Sensors for daily life: A review”, *Sensors International*, sv. 2, 2021., pristupljeno: 23.4.2026. <https://doi.org/10.1016/j.sintl.2021.100121>
- [10] Kelvin, “Sensor app”, <https://play.google.com/store/apps/details?id=com.kelvin.sensorapp>, 2026., pristupljeno: 18.6.2026.
- [11] Carnegie Mellon University – CS2N, “Inertial sensors – rebuild race”, https://www.cs2n.org/u/mp/badge_pages/3755, 2026., pristupljeno: 28.4.2026.
- [12] K. Alexis, “Inertial sensors”, <http://www.kostasalexis.com/inertial-sensors.html>, 2026., pristupljeno: 28.4.2026.
- [13] J. Jose, “Introduction to time series analysis and its applications”, Nastavni materijal, CHRIST (Deemed to be University), Bangalore, India, 2022.
- [14] R. R. Weber, “Time series”, <https://www.statslab.cam.ac.uk/~rrw1/timeseries/t.pdf>, 2022., pristupljeno: 5.5.2026.
- [15] MathWorks, “Time series analysis”, <https://it.mathworks.com/discovery/time-series-analysis.html>, 2026., pristupljeno: 7.5.2026.
- [16] Zavod za elektroničke sustave i obradbu informacija, “Osnove obradbe signala: Filtracija”, Nastavni materijal, Fakultet elektrotehnike i računarstva, Zagreb, 2026., pristupljeno: 5.5.2026.
- [17] —, “Osnove obradbe signala: Digitalni filtri”, Nastavni materijal, Fakultet elektrotehnike i računarstva, Zagreb, 2026., pristupljeno: 5.5.2026.

- [18] S. Singh, “Human activity recognition (har): Fundamentals, models, datasets”, Labellerr AI, 2023., pristupljeno: 7.5.2026. [Mrežno]. Adresa: <https://www.labellerr.com/blog/human-activity-recognition/>
- [19] E. Cero Dinarević, J. Baraković Husić, i S. Baraković, “Step by step towards effective human activity recognition: A balance between energy consumption and latency in health and wellbeing applications”, *Sensors*, sv. 19, br. 23, str. 5206, 2019., pristupljeno: 9.5.2026. <https://doi.org/10.3390/s19235206>
- [20] J. Suto, S. Oniga, i P. Pop Sitar, “Feature analysis to human activity recognition”, *International Journal of Computers, Communications & Control*, sv. 12, br. 1, str. 116–130, 2017. <https://doi.org/10.15837/ijccc.2017.1.2787>
- [21] Fakultet elektrotehnike i računarstva, “Strojno učenje: Stroj potpornih vektora”, https://www.fer.unizg.hr/_download/repository/SU1-2022-P08-StrojPotpornihVektora.pdf, 2022., pristupljeno: 18.6.2026.
- [22] J. Šnajder, “Strojno učenje: Neparametarske metode”, Nastavni materijal, Fakultet elektrotehnike i računarstva, Zagreb, 2019., pristupljeno: 9.5.2026. [Mrežno]. Adresa: https://www.fer.unizg.hr/_download/repository/SU-2018-11-NeparametarskeMetode.pdf
- [23] Microsoft Corporation, *LightGBM: Features*, 2026., pristupljeno: 18.6.2026. [Mrežno]. Adresa: <https://lightgbm.readthedocs.io/en/stable/Features.html>
- [24] GeeksforGeeks, “Introduction to recurrent neural network”, <https://www.geeksforgeeks.org/machine-learning/introduction-to-recurrent-neural-network/>, 2026., pristupljeno: 18.6.2026.
- [25] O. D. Lara i M. A. Labrador, “A survey on human activity recognition using wearable sensors”, *IEEE Communications Surveys & Tutorials*, sv. 15, br. 3, str. 1192–1209, 2013., pristupljeno: 7.5.2026. <https://doi.org/10.1109/SURV.2012.110112.00192>
- [26] F. Slothower, “Activity recognition using the wisdm dataset”, University of California, Irvine, teh. izv., 2020., project Report, Department of Mechanical

Engineering. Pristupljeno: 3.9.2026. [Mrežno]. Adresa: https://felixslothower.com/assets/pdf/report_actvt.pdf

- [27] S. Benavidez i D. McCreight, “A deep learning approach for human activity recognition”, Stanford University, teh. izv., 2019., cS230: Deep Learning, Project Report. Pristupljeno: 1.9.2026. [Mrežno]. Adresa: https://cs230.stanford.edu/projects_fall_2019/reports/26221049.pdf
- [28] Y. Chen, K. Zhong, J. Zhang, Q. Sun, i X. Zhao, “Lstm networks for mobile human activity recognition”, u *Proceedings of the 2016 International Conference on Artificial Intelligence: Technologies and Applications (ICAITA)*. Atlantis Press, 2016., str. 258–262, wISDM dataset, 6 activities, accuracy 92.1%. Pristupljeno: 3.9.2026. [Mrežno]. Adresa: <https://www.atlantis-press.com/proceedings/icaita-16/25849464>
- [29] Chrissi2802, “Wisdm—biometric time series data classification”, 2022., gitHub repository, Kaggle competition on WISDM (6 activities). Pristupljeno: 3.9.2026. [Mrežno]. Adresa: <https://github.com/Chrissi2802/WISDM---Biometric-time-series-data-classification>
- [30] M. M. Hossain, T. A. Han, S. S. Ara, i Z. U. Shamszaman, “Benchmarking classical, deep, and generative models for human activity recognition”, *arXiv preprint*, 2025., arXiv:2501.08471. WISDM (6 activities), Random Forest accuracy $\approx 64\%$. Pristupljeno: 3.9.2026. [Mrežno]. Adresa: <https://arxiv.org/abs/2501.08471>
- [31] T.-H. Tan, J.-Y. Shih, S.-H. Liu, M. Alkhaleefah, Y.-L. Chang, i M. Gochoo, “Using a hybrid neural network and a regularized extreme learning machine for human activity recognition with smartphone and smartwatch”, *Sensors*, sv. 23, br. 6, str. 3354, 2023., pristupljeno: 1.9.2026. <https://doi.org/10.3390/s23063354>

Izjava o korištenju umjetne inteligencije

Gemini (Google): korišten kao jezični model za provjeru gramatičke ispravnosti teksta i stilsko oblikovanje rečenica.

Perplexity AI: korišten u početnoj fazi rada za istraživanje literature, generiranje ideja za metodološki okvir te planiranje strukture eksperimentalnog dijela.

ChatGPT (OpenAI): korišten kao pomoćni alat za pretraživanje i formatiranje bibliografskih jedinica.

Osvrt na korištenje umjetne inteligencije: Alati umjetne inteligencije korišteni su kao podrška u pisanju i organizaciji materijala. Sve odluke, poput odabira arhitekture modela, analize rezultata te donošenja zaključaka, rezultat su mog samostalnog rada i kritičkog promišljanja. Tijekom korištenja alata povremeno su zabilježene nepreciznosti ili netočne tvrdnje (halucinacije), koje su pravovremeno uočene i ispravljene vlastitom provjerom.

Izjava o korištenju umjetne inteligencije: Potvrđujem da sam tijekom izrade ovog diplomskog rada koristio umjetnu inteligenciju u skladu s Politikom primjerenog korištenja umjetne inteligencije na Fakultetu elektrotehnike i računarstva, te da umjetna inteligencija nije zamijenila moje kritičko razmišljanje niti moj doprinos.