SAP projekt

FMMJ

15.01.2024.

Učitavanje podatka i analiza dataseta

```
nba=read.csv("datasets/all seasons.csv")
dim(nba)
## [1] 12844
                 22
names (nba)
##
    [1] "X"
                              "player name"
                                                   "team abbreviation"
    [4] "age"
                              "player_height"
                                                   "player_weight"
##
       "college"
                              "country"
##
    [7]
                                                   "draft_year"
                              "draft_number"
        "draft_round"
##
  [10]
                                                   "gp"
        "pts"
                              "reb"
                                                   "ast"
  [13]
   [16]
        "net_rating"
                              "oreb_pct"
                                                   "dreb_pct"
        "usg_pct"
##
   [19]
                              "ts_pct"
                                                   "ast_pct"
  [22] "season"
print(head(nba, 5))
##
            player_name team_abbreviation age player_height player_weight
## 1 0 Randy Livingston
                                        HOU
                                             22
                                                        193.04
                                                                     94.80073
## 2 1 Gaylon Nickerson
                                             28
                                        WAS
                                                        190.50
                                                                     86.18248
## 3 2
           George Lynch
                                             26
                                                        203.20
                                                                    103.41898
                                        VAN
## 4 3
         George McCloud
                                             30
                                                        203.20
                                                                    102.05820
                                        LAL
## 5 4
                                             23
           George Zidek
                                        DEN
                                                        213.36
                                                                    119.74829
##
                    college country draft_year draft_round draft_number gp
                                                                               pts reb
## 1
           Louisiana State
                                 USA
                                           1996
                                                           2
                                                                        42 64
                                                                               3.9 1.5
                                                           2
## 2 Northwestern Oklahoma
                                 USA
                                                                        34 4
                                                                               3.8 1.3
                                           1994
## 3
            North Carolina
                                 USA
                                           1993
                                                           1
                                                                        12 41
                                                                               8.3 6.4
## 4
                                 USA
                                                           1
                                                                         7 64 10.2 2.8
             Florida State
                                           1989
## 5
                       UCLA
                                 USA
                                           1995
                                                           1
                                                                        22 52
                                                                               2.8 1.7
##
     ast net_rating oreb_pct dreb_pct usg_pct ts_pct ast_pct
                                                                 season
                                                 0.487
                                                          0.248 1996-97
## 1 2.4
                 0.3
                        0.042
                                  0.071
                                          0.169
## 2 0.3
                 8.9
                        0.030
                                  0.111
                                          0.174 0.497
                                                          0.043 1996-97
## 3 1.9
                -8.2
                        0.106
                                  0.185
                                          0.175
                                                 0.512
                                                          0.125 1996-97
## 4 1.7
                -2.7
                        0.027
                                  0.111
                                          0.206
                                                 0.527
                                                          0.125 1996-97
## 5 0.3
               -14.1
                        0.102
                                  0.169
                                          0.195
                                                 0.500
                                                          0.064 1996-97
```

Vidimo da dataset sadrži igrače i sezonu u kojoj su igrali kao i njihove statistike u toj sezoni.


1. Razlikuje li se broj poena igrača po sezoni kroz različita desetljeća?

Prvotno, čistimo podatke i provjeravamo jesu li neki dijelovi neispravni ili nepotrebni. Prvo provjeravamo postoje li nedostajuće vrijednosti. Za odgovor na ovo pitanje nam također ne trebaju sve varijable.

```
library(dplyr)
## Attaching package: 'dplyr'
## The following objects are masked from 'package:stats':
##
       filter, lag
## The following objects are masked from 'package:base':
##
##
       intersect, setdiff, setequal, union
sum(!complete.cases(nba))
## [1] 0
nba1 = select (nba,c("player_name","gp", "pts","season"))
print(head(nba1, 5))
##
          player_name gp pts season
## 1 Randy Livingston 64 3.9 1996-97
## 2 Gaylon Nickerson 4 3.8 1996-97
         George Lynch 41 8.3 1996-97
## 4
       George McCloud 64 10.2 1996-97
## 5
         George Zidek 52 2.8 1996-97
Nema nedostajućih vrijednosti.
Prvo ćemo vrijednosti varijable "season", tipa string, odvojiti s operatorom "-" i pretvoriti u integer.
x <- list()
year_season <- nba1$season</pre>
year_season <- strsplit(year_season,split="-",fixed=T)</pre>
for (i in seq_along(year_season)) {
  x<-append(x,year_season[[i]][1])
nba1$"year_season"<-strtoi(x) #pretvaramo u integer</pre>
Sada ćemo odvojiti tablicu u različite tablice po desetljećima kako bi ih mogli uspoređivati.
ind= which(nba1$year season < 2000)</pre>
nba90s = nba1[ind,]
ind=which(nba1$year_season > 1999 & nba1$year_season <2010)
nba00s = nba1[ind,]
ind=which(nba1$year_season > 2009 & nba1$year_season <2020)
nba10s = nba1[ind,]
ind=which(nba1$year_season > 2019 & nba1$year_season <2030)</pre>
nba20s = nba1[ind,]
Idemo usporediti podatke za različita desetljeća.
boxplot(nba90s$pts, nba00s$pts, nba10s$pts, nba20s$pts,
        names = c('90s points','00s points','10s points', '20s points'),
```

main='Boxplot of points throughout decades')

Boxplot of points throughout decades



Prema boxplotu vidimo da su 2010te i 2020te imaju ponešto veći prvi kvartil, ali ne možemo zaključiti da je ta razlika značajna. Ove podatke također možemo vidjeti iz deskriptivne statistike.

```
summary(nba90s$pts)
##
      Min. 1st Qu.
                     Median
                                Mean 3rd Qu.
                                                 Max.
      0.00
                       6.40
##
              3.20
                                7.83
                                       11.20
                                                29.70
summary(nba00s$pts)
##
      Min. 1st Qu.
                     Median
                                Mean 3rd Qu.
                                                 Max.
     0.000
             3.400
                      6.500
##
                               8.103
                                     11.500
                                               35.400
summary(nba10s$pts)
      Min. 1st Qu.
##
                     Median
                                Mean 3rd Qu.
                                                 Max.
     0.000
             3.800
                      6.900
                               8.266
                                     11.600
                                               36.100
summary(nba20s$pts)
##
      Min. 1st Qu.
                     Median
                                Mean 3rd Qu.
                                                 Max.
##
     0.000
             3.900
                      7.100
                               8.747
                                     11.800
                                              33.100
```

S obzirom da uspoređujemo više populacija kojima je glavna razlika desetljeće - sezona igre, koristit ćemo ANOVU (analizu varijance). Pretpostavit ćemo da su populacije nezavisne tj. glavna nezavisna varijabla je desetljeće.

Potrebno je još provjeriti jesu li populacije normalno distribuirane i ispitati homogenost varijanci. Za

nezavisnost koristimo Lillieforsovu inačicu KS testa.

 H_0 : Podaci su normalno distribuirani. H_1 : Podaci nisu normalno distribuirani.


```
require(nortest)
## Loading required package: nortest
lillie.test(nba90s$pts)
##
   Lilliefors (Kolmogorov-Smirnov) normality test
##
##
## data: nba90s$pts
## D = 0.1035, p-value < 2.2e-16
lillie.test(nba00s$pts)
##
##
   Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: nba00s$pts
## D = 0.10988, p-value < 2.2e-16
lillie.test(nba10s$pts)
##
##
   Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: nba10s$pts
## D = 0.10054, p-value < 2.2e-16
lillie.test(nba20s$pts)
##
##
    Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: nba20s$pts
## D = 0.11262, p-value < 2.2e-16
Prema Lillieforsovom testu, p- vrijednost je iznimno mala i zato odbacujemo nul-hipotezu. Populacije nisu
```

normalno distribuirane.

Možemo probati transformacijom podataka doći do homogenosti i normalnosti.


```
hist(log(nba90s$pts))
```

Histogram of log(nba90s\$pts)



hist(1/(nba90s\$pts))

Histogram of 1/(nba90s\$pts)



Unatoč transformacijama, dataset još uvijek nije normalno distribuiran. S obzirom da nisu ispunjeni uvjeti za običnu ANOVU, pristupamo neparametarskoj ANOVI - Kruskal Wallis testu.

 H_0 : Poeni igrača se ne razlikuju kroz različita desetljeća.

 H_1 : Poeni igrača se razlikuju kroz različita desetljeća.

```
kruskal_test_result <- kruskal.test(list(nba90s$pts, nba00s$pts, nba10s$pts, nba20s$pts))</pre>
print(kruskal_test_result)
##
##
    Kruskal-Wallis rank sum test
##
## data: list(nba90s$pts, nba00s$pts, nba10s$pts, nba20s$pts)
## Kruskal-Wallis chi-squared = 23.071, df = 3, p-value = 3.903e-05
kruskal_test_result <- kruskal.test(list(nba90s$pts, nba00s$pts))</pre>
print(kruskal_test_result)
##
##
    Kruskal-Wallis rank sum test
##
## data: list(nba90s$pts, nba00s$pts)
## Kruskal-Wallis chi-squared = 1.6137, df = 1, p-value = 0.204
kruskal_test_result <- kruskal.test(list(nba00s$pts, nba10s$pts))</pre>
print(kruskal_test_result)
##
```

Kruskal-Wallis rank sum test

```
##
## data: list(nba00s$pts, nba10s$pts)
## Kruskal-Wallis chi-squared = 7.9644, df = 1, p-value = 0.004771
kruskal_test_result <- kruskal.test(list(nba10s$pts, nba20s$pts))
print(kruskal_test_result)

##
## Kruskal-Wallis rank sum test
##
## data: list(nba10s$pts, nba20s$pts)
## Kruskal-Wallis chi-squared = 2.1872, df = 1, p-value = 0.1392
#zaključak</pre>
```


S obzirom da je p-vrijednost mala, postoji značajna razlika u bodovima između desetljeća i odbacujemo nul-hipotezu te prihvaćamo alternativu. Vidimo da je značajna razlika između 2000-ih i 2010-ih i obzirom da 2010-te i 2020-te nemaju značajnu razliku, možemo zaključiti da se broj poena povećava samo u prijelazu s 2000-ih na 2010te.

2. Postoji li značajna statistička razlika u visini igrača koji igraju za ekipe zapadne od igrača koji igraju za ekipe istočne konferencije?

Razdvojimo dataset na "konferencijske datasetove"


Napravimo deskriptivnu analizu

Boxplot of west and east player heights




```
hist(all.seasons.west$player_height,
    main='Histogram of Heights of West Side Players',
    xlab='')
```

Histogram of Heights of West Side Players



```
hist(all.seasons.east$player_height,
    main='Histogram of heights of East side players',
    xlab='')
```

Histogram of heights of East side players



Uspoređivanje srednjih vrijednosti visina igrača istoka i zapada daje indikaciju da nema značajne razlike u visinama igrača.


Najprije provjeravamo pretpostavke nezavisnosti i normalnosti uzorke.

Nezavisnost možemo pretpostaviti obzirom na to da se radi o dva uzorka iz različitih dijelova zemlje.

Za provjeru normalnosti koristimo Q-Q plot-ove.


```
qqnorm(all.seasons.west$player_height, pch = 1, frame = FALSE, main='West side playes')
qqline(all.seasons.west$player_height, col = "steelblue", lwd = 2)
```

West side playes



```
qqnorm(all.seasons.east$player_height, pch = 1, frame = FALSE, main='East side playes')
qqline(all.seasons.east$player_height, col = "steelblue", lwd = 2)
```

East side playes



Na Q-Q plotu primjećujemo manja odstupanja od teoretske linije, no smatramo ih zanemarivima te zaključujemo da su podaci dovoljno blizu očekivane normalne distribucije.

Sljedeće uspoređujemo varijance naših uzoraka.

```
var.test(all.seasons.west$player_height, all.seasons.east$player_height)
```

```
##
## F test to compare two variances
##
## data: all.seasons.west$player_height and all.seasons.east$player_height
## F = 1.0703, num df = 1740, denom df = 1750, p-value = 0.1562
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
## 0.974377 1.175604
## sample estimates:
## ratio of variances
## 1.070265
```

Na temelju p-vrijednosti iz provedenog testa zaključujemo da su varijance jednake te nastavljamo dalje s t-testom uz pretpostavku jednakosti varijanci.

 H_0 : nema razlike u srednjim visinama igrača Istočne i Zapadne konferencije.

 H_1 : postoji razlika u srednjim visinama igrača Istočne i Zapadne konferencije.

```
t.test(all.seasons.west$player_height, all.seasons.east$player_height, var.equal = TRUE)
```

##

```
## Two Sample t-test
##

## data: all.seasons.west$player_height and all.seasons.east$player_height
## t = -0.56292, df = 3490, p-value = 0.5735
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -0.7705822  0.4268005
## sample estimates:
## mean of x mean of y
## 200.0159  200.1878
#zaključak
```

Nakon izvođenja t-testa, možemo zaključiti da nema statistički značajne razlike u visini između igrača koji predstavljaju timove zapada i onih koji predstavljaju timove istoka. Drugim riječima, nemamo dovoljno dokaza da odbacimo nultu hipotezu u korist alternativne hipoteze na razini značajnosti od 5%.

3. Možemo li predvidjeti prosječni broj poena igrača u sezoni s obzirom na njegove biometrijske podatke?

```
library(dplyr)
```

#Jednostavna regresija

Za procjenu utjecaja biometrijskih podataka na broj poena treba napraviti tri modela jednostavne regresije, po jedan za svaki biometrijski podatak: visina, težina i dob.

```
data_perheight <- nba %>%
    group_by(player_height) %>%
    summarize(avg_pts = mean(pts, na.rm = TRUE))

data_perweight <- nba %>%
    group_by(player_weight) %>%
    summarize(avg_pts = mean(pts, na.rm = TRUE))

data_perage <- nba %>%
    group_by(age) %>%
    summarize(avg_pts = mean(pts, na.rm = TRUE))

fit.height = lm(avg_pts~player_height,data=data_perheight)

fit.weight = lm(avg_pts~player_weight,data=data_perweight)

fit.age = lm(avg_pts~age,data=data_perage)
```

Ako pogledamo sve mjere nad modelima možemo zaključiti koji biometrijski podatci su značajni, a koji nisu: summary(fit.height)

```
## (Intercept)
                  3.94271
                             5.28114
                                       0.747
                                                0.462
                             0.02651
                                       0.579
                                                0.567
## player_height 0.01534
##
## Residual standard error: 2.762 on 28 degrees of freedom
## Multiple R-squared: 0.01182,
                                    Adjusted R-squared:
## F-statistic: 0.335 on 1 and 28 DF, p-value: 0.5674
summary(fit.weight)
##
## Call:
## lm(formula = avg_pts ~ player_weight, data = data_perweight)
##
## Residuals:
##
      Min
                1Q Median
                                3Q
                                       Max
## -8.1622 -1.6845 -0.0269 1.6269 18.8048
## Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
## (Intercept)
                  6.45778
                             1.39498
                                       4.629 7.71e-06 ***
## player_weight 0.01472
                             0.01306
                                       1.127
                                                0.261
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.638 on 155 degrees of freedom
## Multiple R-squared: 0.00813,
                                    Adjusted R-squared:
## F-statistic: 1.271 on 1 and 155 DF, p-value: 0.2614
summary(fit.age)
##
## Call:
## lm(formula = avg_pts ~ age, data = data_perage)
## Residuals:
                1Q Median
##
       Min
                                3Q
                                       Max
## -4.2331 -0.9082 0.0634 1.3108 2.0252
##
## Coefficients:
##
               Estimate Std. Error t value Pr(>|t|)
## (Intercept) 11.02113
                           1.27642
                                    8.634 5.69e-09 ***
               -0.13082
                           0.03993 -3.276 0.00308 **
## age
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.616 on 25 degrees of freedom
## Multiple R-squared: 0.3003, Adjusted R-squared: 0.2723
## F-statistic: 10.73 on 1 and 25 DF, p-value: 0.003084
Vidi se da je statistički značajan samo podatak dobi jer on jedini ima malu p-vrijednost. Također, koeficijent
```

Vidi se da je statistički značajan samo podatak dobi jer on jedini ima malu p-vrijednost. Također, koeficijent determinacije objašnjava 30.03% varijance podataka.

Statističku značajnost dobi potvrđuje i korelacijski test:

```
cor.test(data_perage$age,data_perage$avg_pts)
```

##


```
## Pearson's product-moment correlation
##
## data: data_perage$age and data_perage$avg_pts
## t = -3.2758, df = 25, p-value = 0.003084
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.7680799 -0.2122023
## sample estimates:
## cor
## -0.5480237
```

P-vrijednost 0.003084 je jako mala što dovodi do odbacivanja nulte hipoteze, tj. postoji značajna nenulta korelacija između dobi igrača i njegovih postignutih bodova.

Ako se grafički prikažu podatci tog modela može se naznačiti i nagib pravca linearne regresije koji pokazuje negativan utjecaj varijable dobi na broj postignutih poena:

```
plot(data_perage$age,data_perage$avg_pts, main = "Age")
lines(data_perage$age,fit.age$fitted.values,col='red')
```


Age



Ali, postoji i bolji način prilagodbe modela podatcima koristeći kvadratnu regresiju:

```
fit.age.sq <- lm(avg_pts ~ poly(age, 2, raw = TRUE), data = data_perage)
plot(data_perage$age, data_perage$avg_pts, main = "Age")
lines(data_perage$age, predict(fit.age.sq), col = 'red')</pre>
```

Age



summary(fit.age.sq)

```
##
## Call:
## lm(formula = avg_pts ~ poly(age, 2, raw = TRUE), data = data_perage)
##
## Residuals:
##
        Min
                  1Q
                       Median
                                    3Q
                                             Max
  -1.26264 -0.27149
                      0.08976
                              0.35353
                                        0.68243
##
##
  Coefficients:
##
                               Estimate Std. Error t value Pr(>|t|)
## (Intercept)
                             -13.665646
                                           1.617494
                                                    -8.449 1.19e-08 ***
## poly(age, 2, raw = TRUE)1
                               1.569198
                                           0.108819 14.420 2.55e-13 ***
  poly(age, 2, raw = TRUE)2
                              -0.027420
                                           0.001744 -15.720 3.89e-14 ***
##
## Signif. codes:
                     '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4908 on 24 degrees of freedom
## Multiple R-squared: 0.9381, Adjusted R-squared: 0.9329
## F-statistic: 181.8 on 2 and 24 DF, p-value: 3.185e-15
```


Grafički se vidi da model bolje prikazuje podatke, a koristeći summary vidimo i da objašnjava 93.81% varijance. Budući da taj model najbolje objašnjava podatke, taj model će se koristiti i u idućem podzadatku.

Moraju se potvrditi i pretpostavke o regresorima i residualima. U multivarijatnoj regresiji regresori ne smiju biti međusobno jako korelirani, normalnost reziduala i homogenost varijance. Dobra provjera normalnosti

reziduala je i kvantil-kvantil plot:

```
qqnorm(rstandard(fit.age.sq))
qqline(rstandard(fit.age.sq))
```

Normal Q-Q Plot



Kvantil-kvantil plot je relativno ravan što ukazuje na normalnu razdiobu reziduala, ali za potvrdu koristan je i KS test na normalnost:

```
ks.test(rstandard(fit.age.sq),'pnorm')

##

## Exact one-sample Kolmogorov-Smirnov test

##

## data: rstandard(fit.age.sq)

## D = 0.11685, p-value = 0.8137

## alternative hypothesis: two-sided
```

Zbog velike p-vrijednosti (p-value=0.8137) ne odbacuje se nul-hipoteza tj. razdioba reziduala je normalna. Vidi se po svim grafovima i testu da reziduali imaju normalnu razdiobu.

#Višestruka regresija

Što ako se koristi više biometrijskih podataka u jednom modelu?

Za višestruku regresiju treba se prvo provjeriti da parovi varijabli nisu previše korelirani.

```
cor(cbind(nba$player_height,nba$player_weight,nba$age))
```

```
## [,1] [,2] [,3]
## [1,] 1.000000000 0.82214119 -0.007903669
## [2,] 0.822141192 1.00000000 0.063560952
```

```
## [3,] -0.007903669 0.06356095 1.000000000
```

Iz tablice se vidi da su visina i težina igrača previše korelirane varijable (cor=0.82214), a visina i dob najmanje korelirane (cor=-0.0079). To znači da se za višestruku regresiju moe koristiti model s visinom i dobi, ali i model s težinom i dobi jer je i njihova korelacija relativno mala (cor=0.06356).

```
fit.heightage = lm(pts ~ player_height + poly(age, 2, raw = TRUE), nba)
summary(fit.heightage)
##
## Call:
## lm(formula = pts ~ player_height + poly(age, 2, raw = TRUE),
##
       data = nba)
##
## Residuals:
     Min
             1Q Median
                           3Q
                                 Max
## -9.420 -4.525 -1.492 3.199 27.120
##
## Coefficients:
##
                             Estimate Std. Error t value Pr(>|t|)
## (Intercept)
                            -8.184458
                                        2.227244 -3.675 0.000239 ***
                                        0.005791 -5.684 1.35e-08 ***
## player_height
                             -0.032914
## poly(age, 2, raw = TRUE)1 1.654738
                                        0.132189 12.518 < 2e-16 ***
## poly(age, 2, raw = TRUE)2 -0.028996
                                        0.002328 -12.456 < 2e-16 ***
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 5.972 on 12840 degrees of freedom
## Multiple R-squared: 0.01508,
                                   Adjusted R-squared: 0.01485
## F-statistic: 65.52 on 3 and 12840 DF, p-value: < 2.2e-16
fit.weightage = lm(pts ~ player_weight + poly(age, 2, raw = TRUE), nba)
summary(fit.weightage)
##
## Call:
## lm(formula = pts ~ player_weight + poly(age, 2, raw = TRUE),
##
       data = nba)
##
## Residuals:
##
     Min
             10 Median
                            3Q
                                 Max
## -9.094 -4.534 -1.503 3.227 27.260
## Coefficients:
                              Estimate Std. Error t value Pr(>|t|)
## (Intercept)
                                         1.888012 -7.475 8.25e-14 ***
                            -14.112127
## player_weight
                                         0.004253 -2.917 0.00354 **
                             -0.012406
## poly(age, 2, raw = TRUE)1
                              1.693453
                                         0.132150 12.815 < 2e-16 ***
## poly(age, 2, raw = TRUE)2 -0.029631
                                         0.002327 -12.732 < 2e-16 ***
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 5.977 on 12840 degrees of freedom
## Multiple R-squared: 0.01325,
                                   Adjusted R-squared: 0.01302
```

F-statistic: 57.48 on 3 and 12840 DF, p-value: < 2.2e-16

Ako usporedimo ove modele s modelom koji koristi samo dob možemo zaključiti da makar imaju manju p-vrijednost, objašnjavaju manje varijance podataka pa nisu bolji od modela koji korissti samo dob za predikciju.

#BMI

Što ako se uzme BMI igrača?

```
nba$player_BMI <- nba$player_weight / (nba$player_height ^ 2)</pre>
data_perBMI <- nba %>%
  group_by(player_BMI) %>%
  summarize(avg_pts = mean(pts, na.rm = TRUE))
fit.BMI = lm(avg_pts~player_BMI,data=data_perBMI)
summary(fit.BMI)
##
## Call:
## lm(formula = avg_pts ~ player_BMI, data = data_perBMI)
## Residuals:
##
      Min
               10 Median
                               30
## -8.3893 -3.1325 -0.6725 2.1610 23.6866
##
## Coefficients:
##
              Estimate Std. Error t value Pr(>|t|)
## (Intercept)
                 3.094 1.499
                                    2.064 0.03928 *
                                    2.991 0.00286 **
## player_BMI 1783.942
                          596.464
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 4.595 on 886 degrees of freedom
## Multiple R-squared: 0.009995,
                                   Adjusted R-squared:
## F-statistic: 8.945 on 1 and 886 DF, p-value: 0.002859
```

Mjere modela ukazuju na to da je BMI statistički značajan podatak. Ali ono što se još mora provjeriti je normalnost reziduala.

```
ks.test(rstandard(fit.BMI),'pnorm')
```

```
##
##
   Asymptotic one-sample Kolmogorov-Smirnov test
##
## data: rstandard(fit.BMI)
## D = 0.090628, p-value = 9.247e-07
## alternative hypothesis: two-sided
```

P-vrijednost KS testa je jako mala (9.247e-07) što znači da reziduali nisu normalno razdijeljeni.

#Zaključak


Najbolji regresijski model koji je nađen je kvadratni model linearne regresije broja poena i dobi igrača. On objašnjava 93.81% varijance broja poena što znači da možemo koristiti taj model kako bi predvidjeli broj poena igrača.

4. Kakva je veza između dobi igrača i prosječnog broja postignutih poena po sezoni?

Jedine varijable koje će nam biti potrebne su "age" i "pts", odnosno dob i broj poena po utakmici. Nakon što ih izdvojimo, napravimo box plot po godištima.

```
NBA <- nba[,c("age","pts")]</pre>
summary(NBA)
##
         age
                          pts
                            : 0.000
##
    Min.
           :18.00
                     Min.
    1st Qu.:24.00
                     1st Qu.: 3.600
##
##
   Median :26.00
                     Median : 6.700
##
           :27.05
                     Mean
                            : 8.213
##
    3rd Qu.:30.00
                     3rd Qu.:11.500
    Max.
            :44.00
                     Max.
                            :36.100
library(ggplot2)
# box plot
ggplot(NBA, aes(x = factor(age), y = pts)) +
  geom_boxplot() +
  labs(title = "Box Plot of Points by Age Group",
       x = "Age Group",
       y = "Points")
```

Box Plot of Points by Age Group



```
NBA$age <- as.factor(NBA$age)
```


Isprobajmo nad prosjekom bodova po godištu regrsiju 2.stupnja, obzirom da obična linearna regresija ne izgleda kao rješenje i obzirom da je u prošlom podzadatku takav zaključak.

```
avg_ppg_by_age <- aggregate(pts ~ age, data = NBA, FUN = mean)
avg_ppg_by_age$age <- as.numeric(as.character(avg_ppg_by_age$age))

# Fit modela kvadratne regresije
fit.pts.sq <- lm(pts ~ poly(age, 2, raw = TRUE), data = avg_ppg_by_age)

# Plotting
plot(avg_ppg_by_age$age, avg_ppg_by_age$pts, col = 'blue', pch = 16, main = 'Quadratic Regression of Polines(avg_ppg_by_age$age, predict(fit.pts.sq), col = 'red', lw = 2)</pre>
```


Quadratic Regression of Points by Age



```
# Summary
summary(fit.pts.sq)
##
```

```
## poly(age, 2, raw = TRUE)2 -0.027420  0.001744 -15.720 3.89e-14 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4908 on 24 degrees of freedom
## Multiple R-squared: 0.9381, Adjusted R-squared: 0.9329
## F-statistic: 181.8 on 2 and 24 DF, p-value: 3.185e-15
# QQ Plot
qqnorm(rstandard(fit.pts.sq))
qqline(rstandard(fit.pts.sq))
```

Normal Q-Q Plot



Vidimo da smo dobili identičan graf kao u prošlom podzadatku. Po velikoj R squared vrijednosti i niskoj p vrijednosti možemo zaključiti da je ovaj model dobar. Deriviramo li dobivene koeficijente dobivamo da u prosjeku bodovi igrača rastu do 28.61 godina te zatim kreću padati. Isprobajmo još jednu metodu ANOVA


Razdvojimo grupe u individualne grupe po godinama i nazovimo ih age18,age19,age20, te provjerimo koliko instanci ima u njima itd.

```
# Split grupa
age_groups <- split(NBA, NBA$age)

# Napravi individualne grupe
for (age_group_name in names(age_groups)) {
   age_group_data <- age_groups[[age_group_name]]
   assign(paste0("age", age_group_name), age_group_data)
}</pre>
```

Obzirom na mali broj određenih godišta, kombinirajmo sve datasetove u 3 velika dataseta(igrači do 24 godina,

```
igrači između 25 i 30 godina i igrači stariji od 30 godina)
young <- rbind(age18, age19, age20, age21, age22, age23, age24)
prime <- rbind(age25, age26, age27, age28, age29, age30)</pre>
old <- rbind(age31, age32, age33, age34, age35, age36, age37, age38, age39, age40, age41, age42, age43,
summary(young)
##
         age
                        pts
##
   24
           :1333
                   Min. : 0.00
##
   23
           :1218
                   1st Qu.: 3.10
##
  22
           : 817
                   Median: 5.90
                         : 7.52
##
   21
           : 534
                   Mean
##
   20
           : 318
                   3rd Qu.:10.30
           : 76
##
  19
                   Max. :32.40
   (Other):
summary(prime)
                        pts
##
         age
##
   25
                   Min. : 0.000
           :1195
##
   26
           :1058
                   1st Qu.: 4.100
   27
           :1016
                   Median : 7.500
##
##
   28
           : 891
                   Mean
                          : 8.941
           : 813
## 29
                   3rd Qu.:12.400
## 30
           : 741
                   Max.
                          :36.100
## (Other):
summary(old)
##
                       pts
         age
##
   31
           :643
                  Min. : 0.000
##
  32
           :564
                  1st Qu.: 3.600
##
   33
           :467
                  Median : 6.400
                        : 7.796
##
   34
           :367
                  Mean
##
  35
           :257
                  3rd Qu.:10.800
##
   36
           :205
                         :33.000
                  Max.
##
   (Other):328
all_datasets <- list(young = young, prime = prime, old = old)</pre>
par(mfrow = c(1, 3)) # Arrange the plots in one row with three columns
for (i in 1:length(all_datasets)) {
 boxplot(all_datasets[[i]]$pts,
          main = names(all_datasets)[i],
          ylab = "Points (pts)",
          col = "skyblue",
          border = "black",
          ylim = c(0, 15))
}
```



Vidimo da igrači srednje dobi zabijaju više poena i od mladih i starijih igrača. Potrebno je još provjeriti jesu li populacije normalno distribuirane i ispitati homogenost varijanci. Za nezavisnost koristimo Lillieforsovu inačicu KS testa.

 H_0 : Podaci su normalno distribuirani. H_1 : Podaci nisu normalno distribuirani.


```
require(nortest)
lillie.test(young$pts)
##
##
   Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: young$pts
## D = 0.12095, p-value < 2.2e-16
lillie.test(prime$pts)
##
    Lilliefors (Kolmogorov-Smirnov) normality test
##
##
## data: prime$pts
## D = 0.097253, p-value < 2.2e-16
lillie.test(old$pts)
##
##
   Lilliefors (Kolmogorov-Smirnov) normality test
## data: old$pts
```

```
## D = 0.10459, p-value < 2.2e-16
```


Vidljivo je da zbog ekstremno niske p vrijednosti distribucije nisu normalne, isprobajmo 2 transformacije podataka kako bismo došli bliže normalnoj distribuciji


hist(log(young\$pts))

Histogram of log(young\$pts)



hist(1/(log(young\$pts)))





Čak i nakon 2 transformacije vidimo da nismo došli bliže normalnoj distribuciji. Isprobajmu inačicu ANOVE - Kruskal Wallis test koji se koristi u slućaju ne normalnih populacija.

 H_0 : Nema značajne razlike u prosjeku poena po utakmici između populacija.

 ${\cal H}_1$: Ima značajne razlike u prosjeku po
ena po utakmici između populacija

```
kruskal_test_result <- kruskal.test(list(young$pts, prime$pts, old$pts))
print(kruskal_test_result)

##
## Kruskal-Wallis rank sum test
##
## data: list(young$pts, prime$pts, old$pts)
## Kruskal-Wallis chi-squared = 168.07, df = 2, p-value < 2.2e-16</pre>
```

Zbog niske p vrijednosti zaključujemo da populacije nemaju isti prosjek bodova. Isprobajmo kruskal test na mladim igračima i igračima koji su u svome vrhuncu.

```
kruskal_test_result <- kruskal.test(list(young$pts, prime$pts))
print(kruskal_test_result)</pre>
```

```
##
## Kruskal-Wallis rank sum test
##
## data: list(young$pts, prime$pts)
## Kruskal-Wallis chi-squared = 156.02, df = 1, p-value < 2.2e-16</pre>
```

Vidimo zbog niske p vrijednosti i gledajući box plot i summary da je očito da igrači u dobi od 25 do 30 godina imaju veći prosjek poena od mladih igrača. Isprobajmo usporedbu sa starim igračima

```
kruskal_test_result <- kruskal.test(list(prime$pts, old$pts))
print(kruskal_test_result)</pre>
```

```
##
## Kruskal-Wallis rank sum test
##
## data: list(prime$pts, old$pts)
## Kruskal-Wallis chi-squared = 59.096, df = 1, p-value = 1.502e-14
#Zaključak
```

Niska p vrijednost ukazuje ponovno na to da postoji razlika u zabijanju između igrača od 25 do 30 godina i starih igrača. Box plot i summary nam ukazuju da igrači u dobi od 25 do 30 godina zabijaju više od starih igrača

Iz ova 2 testa zaključujemo je da prosjek poena po utakmici igrača raste dok igrač ne uđe u period od 25. do 30. godine, nakon čega opada kako igrač dalje stari.